硕士学位论文

面向低质量数据与资源受限场景的分割-联邦学习协同优化研究

RESEARCH ON COLLABORATIVE OPTIMIZATION OF SPLIT FEDERATED LEARNING FOR LOW-QUALITY DATA AND RESOURCE-CONSTRAINED SCENARIOS

研　　究　　生：田耕
指　导　教　师：唐茗副教授

南方科技大学

二〇二五年六月

国内图书分类号：XXxxx.x　　学校代码：14325
国际图书分类号：xx-x　　密级：公开

工学硕士学位论文

面向低质量数据与资源受限场景的分割-联邦学习协同优化研究

学 位 申 请 人：田耕
指 导 教 师：唐茗副教授
学 科 名 称：电子科学与技术
答 辩 日 期：2020 年 12 月
培 养 单 位：计算机科学与工程系
学位授予单位：南方科技大学

Classified Index: XXxxx.x
U.D.C: xx-x

Thesis for the degree of Master of Engineering

RESEARCH ON COLLABORATIVE OPTIMIZATION OF SPLIT FEDERATED LEARNING FOR LOW-QUALITY DATA AND RESOURCE-CONSTRAINED SCENARIOS

Candidate:	Tian Geng
Supervisor:	Assistant Prof. Alice Bob
Discipline:	Computer Science and Technology
Date of Defence:	December, 2020
Affiliation:	School of System Design and Intelligent Manufacturing
Degree-Conferring-Institution:	Southern University of Science and Technology

目 录

第 1 章 低质量数据下 SFL 的收敛性分析 1
1.1 引言 1
1.2 低质量数据下的 SFL 框架 1
1.2.1 问题背景与数学模型 1
1.2.2 系统架构与算法变体 2
1.2.3 SFL 的训练过程 3
1.2.4 分割-联邦学习的训练目标 4
1.3 收敛性理论推导 4
1.3.1 假设条件 4
1.3.2 MSE 作为损失函数时的收敛性 5
1.3.3 Cross Entorpy 作为损失函数时的收敛性 9
1.4 SFL 收敛性的实验验证 13
1.4.1 实验设置 13
1.5 实验设置 13
1.5.1 超参数对模型收敛性的影响 13
1.5.2 Non-IID 数据对模型收敛性的影响 15
1.5.3 标签噪声对模型收敛性的影响 15
附录 A 18
附录 B 23

第 1 章　低质量数据下 SFL 的收敛性分析

1.1　引言

本章旨在从理论层面剖析 non-IID 数据分布与标签噪声对 SFL 收敛性的联合影响。其中的核心难点在于：如何在收敛性分析框架内，精确刻画标签噪声对收敛行为的量化作用。尽管文献[?] 已在联邦学习领域对标签噪声进行了量化，但其聚焦于模型的泛化能力而非收敛性，故其分析范式无法直接迁移至本场景。据现有文献调研，目前尚无研究在分布式学习算法的收敛性分析中建立标签噪声的量化模型。针对这一缺失，本章提出一种新的分析路径：首先推导标签噪声对随机梯度的一阶矩（期望）与二阶矩（方差）的具体扰动，进而将其嵌入传统的收敛性证明框架以推导收敛速率。该策略不仅成功将标签噪声纳入 SFL 的理论分析体系，也为其他分布式学习算法的收敛性研究提供了通用的方法论参考。在完成理论分析后，本章还通过实验展示了 non-IID 数据和标签噪声对 SFL 收敛造成的实际影响。

1.2　低质量数据下的 SFL 框架

1.2.1　问题背景与数学模型

我们考虑一个包含 N 个客户端的集合，即 $\mathcal{N} = \{1, 2, \cdots, N\}$，这些客户端通过 SFL 协作训练一个全局模型。每个客户端 n 都拥有一个本地数据集 $\mathcal{D}_n^{\text{noi}}$，由于在数据收集和处理过程中可能存在标签错误和人为误差，该数据集可能包含标签噪声[? ?]。$\mathcal{D}_n^{\text{noi}}$ 中的每一个数据样本 i 被表示为 $(x_i, \tilde{y}_i)$，其中带有噪声的标签 $\tilde{y}_i$ 可能与真实标签 y_i 不同，并且不同用户间数据的标签分布不一定是 IID 的。

为了方便起见，我们为每个客户端 n 定义一个干净的数据集 $\mathcal{D}_n^{\text{cle}}$，它与 $\mathcal{D}_n^{\text{noi}}$ 相关联，但其中的标签噪声已被修正。$\mathcal{D}_n^{\text{cle}}$ 中的每个数据样本 i 被表示为 (x_i, y_i)，其标签噪声已通过数据清洗技术被去除。令 $D_n = |\mathcal{D}_n^{\text{noi}}| = |\mathcal{D}_n^{\text{cle}}|$ 表示客户端 n 数据集中数据样本的数量。

在一个 SFL 系统中，我们使用 $\boldsymbol{\omega}$ 来表示全局模型。该全局模型被划分为两个部分：一个 l_c 层的客户端模型，记作 $\boldsymbol{\omega}_c$；一个 l_s 层的服务器模型，记作 $\boldsymbol{\omega}_s$。特别地，客户端模型 $\boldsymbol{\omega}_c$ 和服务器模型 $\boldsymbol{\omega}_s$ 共同构成完整的全局模型，即 $\boldsymbol{\omega} = (\boldsymbol{\omega}_c, \boldsymbol{\omega}_s)$。

1.2.2　系统架构与算法变体

SFL 系统架构中包含两个关键服务器角色（如图 1-1 所示），它们协同工作以支持不同的训练策略：

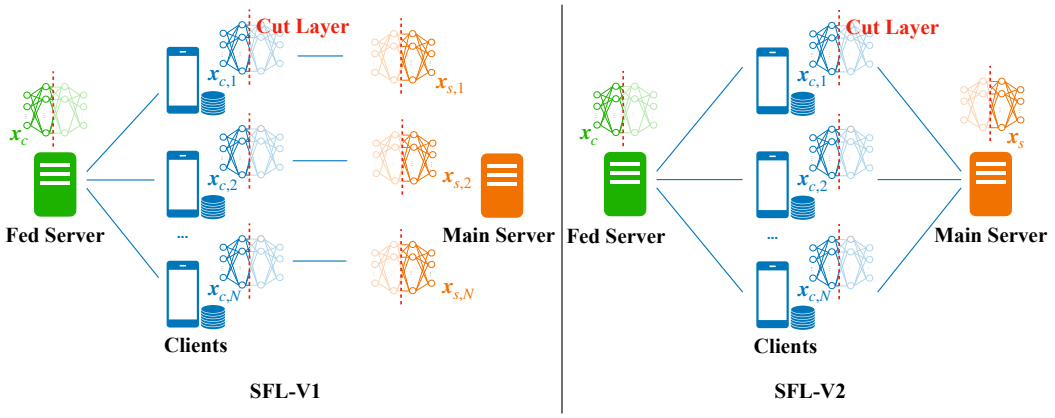

图 1-1　SFL 的两种算法变体：SFL-V1 和 SFL-V2

• **联邦服务器**（Fed Server）：负责聚合各客户端上传的模型参数，以生成全局客户端模型 $\boldsymbol{\omega}_c$。

• **训练服务器**（Training Server）：负责执行服务器端模型的训练任务；此外，在涉及多副本服务器模型的场景下，该服务器还负责对分散的服务器端模型进行聚合，从而生成全局服务器端模型 $\boldsymbol{\omega}_s$。

基于上述架构，SFL 主要存在两种典型的算法变体：SFL-V1 和 SFL-V2[?]。二者最显著的区别在于训练服务器中模型的更新与维护策略。

具体而言，在 SFL-V1 中，训练服务器为每个参与训练的客户端维护一个独立的服务器端模型副本，使得服务器模型与客户端模型之间建立严格的一一映射关系。SFL-V1 的训练流程与 FL 高度相似，其核心差异在于模型计算负载的分配：传统 FL 要求客户端在本地训练完整模型，而 SFL-V1 将模型划分为客户端模型与服务器模型，前者在客户端本地训练，后者在训练服务器上训练。此外，SFL-V1 在聚合阶段需同时对客户端模型参数和服务器模型参数进行聚合，以分别构建全局的客户端模型和全局的服务器模型。

而在 SFL-V2 中，训练服务器上仅维护一个全局共享的服务器模型。每个客户端在训练时均使用该全局服务器模型与本地客户端模型进行交互。此种架构下，客户端模型更多保留了 FL 的分布式聚合特征，而服务器模型则体现了 SL 的集中式训练特征。在模型更新机制上，SFL-V2 仅需对客户端模型进行聚合，训练服务器上的唯一模型作为全局模型直接通过接收到的梯度信息进行更新，无需进行额外的聚合操作。

1.2.3　SFL 的训练过程

SFL 的训练持续 R 轮。在每一轮 r 中，训练流程根据具体的算法变体（SFL-V1 或 SFL-V2）略有不同，但总体遵循以下框架：

1. 模型初始化与分发：在每一轮开始时，客户端 $n \in \mathcal{N}$ 从联邦服务器下载上一轮的全局客户端模型 $\boldsymbol{\omega}_c^{r-1}$，该模型作为第 r 轮中客户端 n 的初始本地模型 $\boldsymbol{\omega}_{c,n}^r$。对于服务器端模型：

- 在 SFL-V1 中，训练服务器为每个客户端 n 维护一个独立的服务器模型副本 $\boldsymbol{\omega}_{s,n}^r$，这些副本由上一轮聚合后的全局服务器模型 $\boldsymbol{\omega}_s^{r-1}$ 初始化。
- 在 SFL-V2 中，训练服务器仅维护一个全局共享的服务器模型 $\boldsymbol{\omega}_s^r$，该模型由上一轮的 $\boldsymbol{\omega}_s^{r-1}$ 直接继承。

2. 客户端与服务器协同训练：在第 r 轮中，每个客户端 n 使用其本地数据集 $\mathcal{D}_n^{\text{noi}}$ 对模型进行 E 个 epoch（即所有训练样本被完整遍历一次的轮次）的训练。在每个 epoch 中，客户端将数据划分为多个小批量（mini-batch），记为 $\zeta_n \subset \mathcal{D}_n^{\text{noi}}$，并依次执行以下四个步骤来完成一个 mini-batch 的更新：

步骤 1：客户端前向传播 客户端 n 使用小批量 ζ_n^{noi} 在其本地模型 $\boldsymbol{\omega}_{c,n}^r$ 上进行前向传播，计算出中间激活值（即切分层的输出）。随后，客户端将这些中间激活值以及对应的标签发送给训练服务器。

步骤 2：训练服务器前向传播 训练服务器接收到中间激活值后，利用当前的服务器端模型（在 V1 中为对应的副本 $\boldsymbol{\omega}_{s,n}^r$，在 V2 中为全局模型 $\boldsymbol{\omega}_s^r$）执行前向传播，生成预测结果并计算损失函数。

步骤 3：训练服务器反向传播 训练服务器根据损失函数计算梯度，并更新相应的服务器端模型参数。由于服务器端模型仅包含完整模型的后 l_s 层，训练服务器会将关于中间激活值的梯度（即“切分层梯度”）发送回客户端 n。

步骤 4：客户端反向传播 客户端 n 接收到梯度后，结合本地保存的前向传播信息，继续完成剩余层的反向传播过程，从而更新本地的客户端模型 $\boldsymbol{\omega}_{c,n}^r$。至此，一个小批量的训练迭代完成。

3. 模型聚合：SFL-V1 和 SFL-V2 的客户端模型聚合频率均为 $\kappa = \left\lceil \frac{D_n}{b} \right\rceil \times E$，SFL-V1 服务器模型的聚合频率为 $\tilde{\kappa}$, 其中 $\tilde{\kappa}$ 与 κ 不一定相等。聚合阶段的具体操作取决于 SFL 的具体变体，其过程入戏：

- **客户端模型聚合**：无论何种变体，联邦服务器都会收集所有客户端上传的 $\boldsymbol{\omega}_{c,n}^r$，并通过加权平均生成新一轮的全局客户端模型 $\boldsymbol{\omega}_c^r$：

$$\boldsymbol{\omega}_c^r = \sum_{n=1}^{N} \frac{|\mathcal{D}_n|}{\sum_{n'=1}^{N} |\mathcal{D}_{n'}|} \boldsymbol{\omega}_{c,n}^r. \tag{1-1}$$

- **服务器模型处理：**
  （1）**SFL-V1**：训练服务器对各客户端对应的服务器模型副本执行与公式1-1中类似的加权平均操作，生成全局服务器模型 $\boldsymbol{\omega}_s^r$，用于初始化下一轮的各个副本。
  （2）**SFL-V2**：由于训练服务器上的全局模型 $\boldsymbol{\omega}_s^r$ 已经在步骤 3 中通过接收到的梯度进行了实时累积更新，因此无需额外的聚合操作。当前的 $\boldsymbol{\omega}_s^r$ 直接作为本轮的全局服务器模型进入下一轮。

当客户端和服务器完成 R 轮训练后，最终的完整全局模型由聚合后的客户端部分和服务器部分组成，即 $\boldsymbol{\omega}^R = (\boldsymbol{\omega}_c^R, \boldsymbol{\omega}_s^R)$。

1.2.4　分割-联邦学习的训练目标

具体而言，令 ζ_n^{cle} 表示客户端 n 的干净数据集 $\mathcal{D}_n^{cle}$ 中的一个小批量。设 $F_n(\boldsymbol{\omega}; \zeta_n^{cle})$ 表示完整模型 $\boldsymbol{\omega}$ 在客户端 n 的小批量 ζ_n^{cle} 上的损失函数。客户端 n 的期望损失为

$$F_n^{cle}(\boldsymbol{\omega}) = \mathbb{E}_{\zeta_n^{cle} \sim \mathcal{D}_n^{cle}} \left[F_n\left(\boldsymbol{\omega}; \zeta_n^{cle}\right) \right]. \tag{1-2}$$

SFL 的目标是学习一个模型 $\boldsymbol{\omega}^*$，使其最小化所有客户端上损失函数 $F_n(\boldsymbol{\omega})$ 的加权平均值[?]：

$$\boldsymbol{\omega}^* = \arg\min_{\boldsymbol{\omega}} f(\boldsymbol{\omega}) \triangleq \sum_{n=1}^{N} \frac{|\mathcal{D}_n|}{\sum_{n'=1}^{N} |\mathcal{D}_{n'}|} F_n^{cle}(\boldsymbol{\omega}). \tag{1-3}$$

值得注意的是，尽管第 1.2.1 至 1.2.3 节中描述的 SFL 训练过程是在所有客户端 $n \in \mathcal{N}$ 的含噪数据集 $\mathcal{D}_n^{\mathrm{noi}}$ 上执行的，但其优化目标仍遵循公式 (1-3) 的定义，即令模型 $\boldsymbol{\omega}^R$ 拟合所有客户端的纯净数据集 $\mathcal{D}_n^{\mathrm{cle}}$。

1.3　收敛性理论推导

本章首先阐述收敛性证明所需的一般假设条件，随后针对均方误差（MSE）与交叉熵（Cross-Entropy）两种损失函数分别进行推导，最后给出相应的收敛性结论。

1.3.1　假设条件

如同许多已有工作（例如[? ? ?]），本章在收敛分析中对随机梯度和损失函数做出一些假设。令 $\boldsymbol{g}_n(\boldsymbol{\omega}, \zeta_n)$ 表示 $F_n(\boldsymbol{\omega}; \zeta_n)$ 在小批量 ζ_n 上的随机梯度，即 $\boldsymbol{g}_n(\boldsymbol{\omega}, \zeta_n) \triangleq \boldsymbol{\nabla} F_n(\boldsymbol{\omega}; \zeta_n)$。令 $\boldsymbol{\nabla} F_n^{cle}(\boldsymbol{\omega})$ 表示客户端 $n \in \mathcal{N}$ 的干净数据集上期望损失 $F_n^{cle}(\boldsymbol{\omega})$ 的梯度，定义见公式 (1-2)。令 $\boldsymbol{\nabla} F_n^{noi}(\boldsymbol{\omega})$ 表示对应于噪声数据集的期

望损失梯度。对于任意客户端 $n \in \mathcal{N}$，来自干净数据集 $\mathcal{D}_n^{cle}$ 的小批量上的随机梯度满足以下假设：

假设 1.1 (均方误差下随机梯度的方差)：对于任意客户端 $n \in \mathcal{N}$，$\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right)$ 在干净小批量上的期望方差是有界的，即：

$$\mathbb{E}_{\zeta_n^{cle} \sim \mathcal{D}_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right) - \boldsymbol{\nabla} F_n^{cle}(\boldsymbol{\omega})\right\|^2\right] \leqslant \phi_n^2. \tag{1-4}$$

假设 1.2 (均方误差下的随机梯度)：对于任意客户端 $n \in \mathcal{N}$，$\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right)$ 在 clean 数据集 $\mathcal{D}_n^{cle}$ 上的期望随机梯度是有界的，即：

$$\mathbb{E}_{\zeta_n^{cle} \sim \mathcal{D}_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right)\right\|^2\right] \leqslant G_n^2. \tag{1-5}$$

假设 1.3 (数据异构性)：所有客户端 $n \in \mathcal{N}$ 的期望梯度 $\boldsymbol{\nabla} F_n(\boldsymbol{\omega})$ 的方差是有界的，即：

$$\left\|\boldsymbol{\nabla} F_n(\boldsymbol{\omega}) - \textstyle\sum_{n \in \mathcal{N}} \boldsymbol{\nabla} F_n(\boldsymbol{\omega})/N\right\|^2 \leqslant \lambda^2. \tag{1-6}$$

这里，$\boldsymbol{\nabla} F_n(\boldsymbol{\omega})$ 同时表示 $\boldsymbol{\nabla} F_n^{cle}(\boldsymbol{\omega})$ 和 $\boldsymbol{\nabla} F_n^{noi}(\boldsymbol{\omega})$。①

此外，本文对损失函数作出如下假设：

假设 1.4 (S-平滑性)：对于任意模型 $\boldsymbol{\omega}_1, \boldsymbol{\omega}_2 \in \mathbb{R}^d$，损失函数是 S-平滑的，即：

$$F_n(\boldsymbol{\omega}_2) \leqslant F_n(\boldsymbol{\omega}_1) + \langle \boldsymbol{\nabla} F_n(\boldsymbol{\omega}_1), \boldsymbol{\omega}_2 - \boldsymbol{\omega}_1 \rangle + \frac{S}{2}\|\boldsymbol{\omega}_2 - \boldsymbol{\omega}_1\|^2.$$

为了处理 SFL 中的模型拆分操作，本文提出以下引理，将期望损失的界分解为两个项，分别对应服务器端和客户端模型。令 $\boldsymbol{\omega}^* \triangleq (\boldsymbol{\omega}_{\mathrm{c}}^*; \boldsymbol{\omega}_{\mathrm{s}}^*)$ 表示使 $f(\boldsymbol{\omega})$ 最小化的最优全局模型，定义见 (1-3)。令 $\boldsymbol{\omega}^R \triangleq (\boldsymbol{\omega}_{\mathrm{c}}^R; \boldsymbol{\omega}_{\mathrm{s}}^R)$ 表示经过 R 轮训练后获得的全局模型。

引理 1.1 (收敛性分析中的模型拆分[?])：通过 SFL 训练得到的模型与最优模型之间的性能差距上界如下：

$$\mathbb{E}\left[f(\boldsymbol{\omega}^R)\right] - f(\boldsymbol{\omega}^*) \leqslant \frac{S}{2}\left(\mathbb{E}||\boldsymbol{\omega}_{\mathrm{s}}^R - \boldsymbol{\omega}_{\mathrm{s}}^*||^2 + \mathbb{E}||\boldsymbol{\omega}_{\mathrm{c}}^R - \boldsymbol{\omega}_{\mathrm{c}}^*||^2\right). \tag{1-7}$$

该引理的证明在附录A.1

1.3.2　MSE 作为损失函数时的收敛性

本节深入探讨 MSE 作为损失函数的设定下，SFL 框架中模型的收敛性质。MSE 是回归任务中最基础且广泛使用的损失度量。为了从概率视角对标签噪声进行建模，我们假设其服从高斯分布。具体而言，针对连续值标签 y_i，我们引入一个加性随机噪声项 ϵ_i 来模拟现实场景中的数据不确定性。形式上，我们将观测到的含

① 注意，non-IID 数据和标签噪声可以建模为相互独立的事件，前者涉及客户端的数据分布，后者涉及标签如何被破坏。

噪标签 $\tilde{y}_i$ 建模为真实标签 y_i 与噪声 ϵ_i 的和：

$$\tilde{y}_i = y_i + \epsilon_i, \tag{1-8}$$

其中，噪声项 ϵ_i 服从均值为 μ、方差为 σ^2 的正态分布，即 $\epsilon_i \sim \mathcal{N}(\mu, \sigma^2)$。为了保证估计的无偏性，即确保引入噪声后标签的期望值保持不变，我们设定噪声均值 $\mu = 0$。在此假设下，含噪数据集可表示为 $\mathcal{D}_{\text{noi}} = \{(x_i, \tilde{y}_i)\}_{i=1}^{N}$。这种基于加性高斯噪声的建模范式已被现有文献广泛采纳，并为分析深度学习模型在噪声环境下的鲁棒性与收敛行为提供了坚实的理论基础[?]。

1.3.2.1　标签噪声对损失函数的影响

令 $h(x_i; \boldsymbol{\omega})$ 表示由参数向量 $\boldsymbol{\omega}$ 确定的模型对输入特征 x_i 的预测输出，模型 $\boldsymbol{\omega}$ 在一个无噪声 mini-batch ζ_n^{cle} 上的 MSE 损失函数 $F_n(\boldsymbol{\omega}; \zeta_n^{cle})$ 定义如下：

$$F_n\left(\boldsymbol{\omega}; \zeta_n^{cle}\right) = \frac{1}{|\zeta_n^{cle}|} \sum_{\left(x_j, y_j\right) \in \zeta_n^{cle}} \left(h\left(x_j; \boldsymbol{\omega}\right) - y_j\right)^2 \tag{1-9}$$

因此，我们可以将含噪声数据集下的损失函数用干净数据集下的损失函数表示如下：

引理 1.2 (带标签噪声的 MSE)：考虑一个小批量 ζ_n^{noi} 及其对应的干净小批量 ζ_n^{cle}，则有

$$F_n\left(\boldsymbol{\omega}; \zeta_n^{noi}\right) = F_n\left(\boldsymbol{\omega}; \zeta_n^{cle}\right) + \frac{1}{|\zeta_n^{noi}|} \sum_{(x_i, \tilde{y}_i) \in \zeta_n^{noi}} \left(\epsilon_i^2 - 2\left(h\left(x_i; \boldsymbol{\omega}\right) - y_i\right)\epsilon_i\right). \tag{1-10}$$

该引理的证明在附录A.2

1.3.2.2　标签噪声对梯度的影响

本节旨在分析标签噪声对随机梯度的影响。在公式(1-4)与(1-5)所定义的随机梯度上界基础上，本节将推导其在标签噪声场景下的新上界。在干净数据集上随机梯度 $\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right)$ 可以表示为：

$$\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right) = \boldsymbol{\nabla}_\omega F_n\left(\boldsymbol{\omega}; \zeta_n^{cle}\right) = \frac{1}{|\zeta_n^{cle}|} \sum_{\left(x_j, y_j\right) \in \zeta_n^{cle}} \boldsymbol{\nabla}_\omega \left(h\left(x_j; \boldsymbol{\omega}\right) - \left(y_j\right)\right)^2 \tag{1-11}$$

在此基础之上，我们可以得到在噪声数据集上的随机梯度 $\boldsymbol{g}_n(\boldsymbol{\omega}, \zeta_n^{noi})$ 与干净数据集上的随机梯度 $\boldsymbol{g}_n(\boldsymbol{\omega}, \zeta_n^{cle})$ 的关系：

引理 1.3 (标签噪声下 MSE 的随机梯度)：

$$\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right) = \boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right) - \frac{1}{|\zeta_n^{noi}|} \sum_{(x_i, y_i + \epsilon_i) \in \zeta_n^{noi}} 2\epsilon_i \boldsymbol{\nabla} h\left(x_i; \boldsymbol{\omega}\right). \tag{1-12}$$

该引理的证明在附录A.3

基于此，我们给出如下两个命题，它们分别界定了含噪声数据集下的随机梯度的方差和期望的平方。

命题 1.1 (均方差损失下含标签噪声的随机梯度的方差)：在假设 1.1 下，任意客户端 $n \in \mathcal{N}$ 在噪声小批量上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)$ 的期望方差是有界的：

$$\mathbb{E}_{\zeta_n^{noi} \sim \mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)-\boldsymbol{\nabla} F_n^{noi}(\boldsymbol{\omega})\right\|^2\right] \leqslant \phi_n^2+H_1^2, \tag{1-13}$$

其中 H_1^2 定义为：

$$\begin{aligned} H_1^2 = & \frac{8\sigma^2}{|\mathcal{D}_n^{noi}|^2} \sum_{(x_i, y_i+\epsilon_i) \in \mathcal{D}_n^{noi}}\left(\boldsymbol{\nabla}_\omega h\left(x_i ; \boldsymbol{\omega}\right)\right)^2 \\ & + \frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|} \sum_{(x_i, y_i+\epsilon_i) \in \mathcal{D}_n^{noi}}\left(\boldsymbol{\nabla}_\omega h\left(x_i ; \boldsymbol{\omega}\right)\right)^2 \end{aligned} \tag{1-14}$$

命题 1.2 (均方差损失下含标签噪声的随机梯度的平方的期望)：在假设 1.2 下，任意客户端 $n \in \mathcal{N}$ 在噪声数据集 $\mathcal{D}_n^{noi}$ 上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)$ 是有界的，即：

$$\mathbb{E}_{\zeta_n^{noi} \sim \mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)\right\|^2\right] \leqslant G_n^2+H_2^2, \tag{1-15}$$

其中 H_2^2 定义为：

$$H_2^2=\sum_{\zeta_n^{noi} \subset \mathcal{D}_n^{noi}} \frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|} \sum_{\left(x_j, y_j+\epsilon_j\right) \in \zeta_n^{noi}}\left(\boldsymbol{\nabla}_\omega h\left(x_j ; \boldsymbol{\omega}\right)\right)^2 \tag{1-16}$$

命题 1.1和 1.2 的证明分别见附录 A.4和 A.5。

1.3.2.3　收敛性结果

然后，我们可以得出使用 MSE 损失函数时关于含噪声数据集的 SFL 收敛性的主要结果。此处沿用了[?] 的证明路径，由于篇幅限制，省略了详细证明。此处我们定义 b 表示 mini-batch 的尺寸，η^r 表示第 r 轮的学习率, 以及：

$$\kappa_{min}=min\{\kappa, \tilde{\kappa}]\}, \quad \kappa_{max}=max\{\kappa, \tilde{\kappa}\}, \quad a_n=\frac{D_n}{\sum_{n'=1}^N D_{n'}}, \quad \forall n.$$

收敛性结果如下，包括 SFL-V1 和 SFL-V2

定理 1.1：SFL-V1 的收敛性（MSE 损失函数）

一般凸情形：: 在假设 1.1–1.4 以及均方差损失函数下，若 $\eta^r \leqslant \frac{1}{2S\kappa}$,

$$\mathbb{E}\left[f\left(\boldsymbol{\omega}^{R}\right)\right]-f^{*} \leqslant \frac{S\left\|\boldsymbol{\omega}^{0}-\boldsymbol{\omega}^{*}\right\|^{2}}{2(R+1)} + O\left(\left(\frac{(\kappa^{2}+\tilde{\kappa})^{2}\left\|\boldsymbol{\omega}^{0}-\boldsymbol{\omega}^{*}\right\|^{2} N}{\kappa_{min}^{2}(R+1)} \sum_{n=1}^{N} a_{n}^{2}\left(\sigma_{n}^{2}+G^{2}+H_{1}^{2}+H_{2}^{2}\right)\right)^{\frac{1}{2}}\right) + O\left(\left(\frac{(\kappa^{2}+\tilde{\kappa})^{2} S\left\|\boldsymbol{\omega}^{0}-\boldsymbol{\omega}^{*}\right\|^{2}}{\kappa_{min}^{2}(R+1)} \sum_{n=1}^{N} a_{n}\left(\sigma_{n}^{2}+G^{2}+H_{1}^{2}+H_{2}^{2}\right)\right)^{\frac{1}{3}}\right). \tag{1-17}$$

非凸情形下: 在假设 1.1–1.4 以及均方差损失函数下，若 $\eta^{r} \leqslant \min\left\{\frac{1}{16S\kappa}, \frac{1}{8SN\kappa\sum_{n=1}^{N} a_{n}^{2}}\right\}$,

$$\frac{1}{R}\sum_{r=0}^{R-1}\eta^{r}\mathbb{E}\left[\left\|\boldsymbol{\nabla}_{\boldsymbol{\omega}} f\left(\boldsymbol{\omega}^{r}\right)\right\|^{2}\right] \leqslant \frac{4}{R\kappa_{min}}\left(f\left(\boldsymbol{\omega}^{0}\right)-f(\omega^{*})\right) + O\left(\frac{NS(\kappa^{2}+\tilde{\kappa}^{2})}{R\kappa_{min}}\sum_{n=1}^{N}(a_{n}^{2}+1)\left(\phi_{n}^{2}+\lambda^{2}+H_{1}^{2}\right)\sum_{R=0}^{R-1}\left(\eta^{r}\right)^{2}\right). \tag{1-18}$$

定理 1.2：SFL-V2 的收敛性（MSE 损失函数）

一般凸情形：: 在假设 1.1–1.4 以及均方差损失函数 (1-9) 下，若 $\eta^{r} \leqslant \frac{1}{2S\kappa}$,

$$\mathbb{E}\left[f\left(\boldsymbol{\omega}^{R}\right)\right]-f^{*} \leqslant \frac{S\left\|\boldsymbol{\omega}^{0}-\boldsymbol{\omega}^{*}\right\|^{2}}{2(R+1)} + O\left(\left(\frac{\left\|\boldsymbol{\omega}^{0}-\boldsymbol{\omega}^{*}\right\|^{2} N}{(R+1)} \sum_{n=1}^{N} a_{n}^{2}\left(\sigma_{n}^{2}+G^{2}+H_{1}^{2}+H_{2}^{2}\right)\right)^{\frac{1}{2}}\right) + O\left(\left(\frac{S\left\|\boldsymbol{\omega}^{0}-\boldsymbol{\omega}^{*}\right\|^{2}}{(R+1)} \sum_{n=1}^{N} a_{n}\left(\sigma_{n}^{2}+G^{2}+H_{1}^{2}+H_{2}^{2}\right)\right)^{\frac{1}{3}}\right). \tag{1-19}$$

非凸情形下: 在假设 1.1–1.4 以及均方差损失函数 (1-9) 下，若 $\eta^{r} \leqslant$

$\min\left\{\frac{1}{16S\kappa}, \frac{1}{8SN^2\kappa}\right\}$，则：

$$\frac{1}{R}\sum_{r=0}^{R-1}\eta^r\mathbb{E}\left[\|\nabla_{\boldsymbol{\omega}} f(\boldsymbol{\omega}^r)\|^2\right] \leqslant \frac{4}{R\kappa}\left(f\left(\boldsymbol{\omega}^0\right) - f(\omega^*)\right) + O\left(\frac{NS\kappa}{R}\sum_{n=1}^{N}(a_n^2+1)\left(\phi_n^2+\lambda^2+H_1^2\right)\sum_{R=0}^{R-1}(\eta^r)^2\right). \tag{1-20}$$

SFL-V1 和 SFL-V2 的收敛界随着客户端噪声的方差 σ^2 增大而增大。这从理论上刻画了在均方差损失下标签噪声如何减缓分割-联邦学习的收敛速度。该定理从数学层面形式化了我们的核心洞察：SFL 中因标签噪声引发的性能衰减，与噪声方差 (σ^2) 呈正比关系。噪声方差越大，H_1^2 与 H_2^2 项随之增大，进而推高期望梯度范数的上界。这意味着优化轨迹将愈发震荡，不仅导致收敛速度减缓，最终模型的性能亦可能欠佳。

1.3.3　Cross Entorpy 作为损失函数时的收敛性

本节将 SFL 的收敛性分析推广至分类任务中广泛采用的 Cross-Entropy 损失函数。鉴于分类任务的标签具有离散特性，我们采用标签随机翻转（Random Flipping）机制来模拟标签噪声。具体而言，设 K 为类别总数，δ 表示噪声率，即原始标签 y_i 被错误替换为其他标签 $\tilde{y}_i$ 的概率。引入指示变量 $r_i \sim \text{Bernoulli}(\delta)$ 来表征样本 (x_i, y_i) 是否发生翻转。在此设定下，含噪数据集仍然可形式化地表示为 $\mathcal{D}_{\text{noi}} = \{(x_i, \tilde{y}_i)\}_{i=1}^N$。

1.3.3.1　标签噪声对损失函数的影响

回顾一下，$h(x_i;\boldsymbol{\omega})$ 是模型 $\boldsymbol{\omega}$ 下特征 x_i 的输出。对于 Cross-Entropy 损失函数，$h(x_i;\boldsymbol{\omega})$ 是一个包含 K 个项的向量，在深度学习中称为 logits。令 $M(x_i, y_i;\boldsymbol{\omega})$ 表示对模型输出的 logits 应用 softmax 函数后的结果，给定输入 x_i 和模型参数 $\boldsymbol{\omega}$ 时模型预测标签 y_i 的概率，其定义如下：

$$M(x_i, y_i;\boldsymbol{\omega}) = \frac{e^{[h(x_i;\boldsymbol{\omega})]_{y_i}}}{\sum_{y\in\mathcal{K}} e^{[h(x_i;\boldsymbol{\omega})]_y}}, \tag{1-21}$$

其中 $[h(x_i;\boldsymbol{\omega})]_{y_i}$ 表示 $h(x_i;\boldsymbol{\omega})$ 中与 y_i 对应的项。模型 $\boldsymbol{\omega}$ 在一个无噪声 mini-batch ζ_n^{cle} 上的 Cross-Entropy 损失函数 $F_n(\boldsymbol{\omega};\zeta_n^{cle})$ 定义如下：

$$F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right) = \frac{1}{|\zeta_n^{cle}|}\sum_{(x_i,y_i)\in\zeta_n^{cle}} -\log\left(M(x_i, y_i;\boldsymbol{\omega})\right), \tag{1-22}$$

在此基础之上，我们可以将含噪声数据集下的损失函数用干净数据集下的损失函数表示如下：

引理 1.4 (带标签噪声的 Cross-Entropy)：考虑一个小批量 ζ_n^{noi} 及其对应的干净小批量 ζ_n^{cle}，则有

$$F_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right) = F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right) + \frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\tilde{y}_j\right)\in\zeta_n^{noi}} r_j\left(-log\left(\frac{M\left(x_j,\tilde{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}\right)\right) \tag{1-23}$$

该引理的证明在附录B.1。

1.3.3.2　标签噪声对梯度的影响

本节旨在分析标签噪声对随机梯度的影响。在公式(1-4)与(1-5)所定义的随机梯度上界基础上，本节将推导其在标签噪声场景下的新上界。在干净数据集上随机梯度 $\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)$ 可以表示为：

$$\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right) = -\frac{1}{|\zeta_n^{cle}|}\sum_{\left(x_j,y_j\right)\in\zeta_n^{cle}} \frac{\boldsymbol{\nabla}_\omega\left(M\left(x_j,y_j;\boldsymbol{\omega}\right)\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)} \tag{1-24}$$

在此基础之上，我们可以得到在噪声数据集上的随机梯度 $\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)$ 与干净数据集上随机梯度 $\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)$ 的关系：

$$\boldsymbol{g}_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right) = \boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)+\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\tilde{y}_j\right)\in\zeta_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\tilde{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\tilde{y}_j;\boldsymbol{\omega}\right)}\right) \tag{1-25}$$

该引理的证明在附录B.2

为了进行收敛性分析，我们假设 $M(x_i,y_i;\boldsymbol{\omega})$ 的梯度与其本身的比值始终有界：

假设 1.5 (与 $M(\cdot)$ 相关的界)：设 $(x_i,\tilde{y}_i)$ 和 $\left(x_j,\tilde{y}_j\right)$ 表示来自 $\mathcal{D}_n^{noi}$ 或 $\mathcal{D}_n^{cle}$ 的任意一对数据样本。假设以下内积始终有上下界：

$$\psi_{min} \leqslant \left\langle \frac{\boldsymbol{\nabla}M(x_i,\tilde{y}_i;\boldsymbol{\omega})}{M(x_i,\tilde{y}_i;\boldsymbol{\omega})}, \frac{\boldsymbol{\nabla}M(x_j,\tilde{y}_j;\boldsymbol{\omega})}{M(x_j,\tilde{y}_j;\boldsymbol{\omega})} \right\rangle \leqslant \psi_{max}, \tag{1-26}$$

接下来，我们分别界定含噪声数据集下的随机梯度的方差和期望的平方。首先，定义 $\Delta \triangleq \psi_{max}-\psi_{min}$，$Z \triangleq |\zeta_n^{noi}| = |\zeta_n^{cle}|$，且 $D \triangleq |\mathcal{D}_n^{noi}| = |\mathcal{D}_n^{cle}|$ 对于所有 $n\in\mathcal{N}$ 成立。基于此，我们给出如下两个命题

命题 1.3 (Cross-Entorpy 损失下含标签噪声的随机梯度的方差)：在假设 1.1 下，任意客户端 $n\in\mathcal{N}$ 在噪声小批量上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)$ 的期望方差是有界的：

$$\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}\left(\boldsymbol{\omega}\right)\right\|^2\right] \leqslant \phi_n^2 + H_3^2, \tag{1-27}$$

其中 H_3^2 定义为：

$$H_3^2 = 4\delta\left(\frac{\Delta}{Z} + \frac{3\Delta}{D}\right) + 4\delta^2\left(4 - \frac{\Delta}{Z} - \frac{3\Delta}{D}\right) \tag{1-28}$$

命题 1.4 (Cross-Entorpy 损失下含标签噪声的随机梯度的平方的期望)：在假设 1.2 下，任意客户端 $n \in \mathcal{N}$ 在噪声数据集 $\mathcal{D}_n^{noi}$ 上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)$ 是有界的，即：

$$\mathbb{E}_{\zeta_n^{noi} \sim \mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)\right\|^2\right] \leqslant G_n^2 + H_4^2, \tag{1-29}$$

其中 H_4^2 定义为：

$$H_4^2 = 4\delta\frac{\Delta}{Z} + 4\delta^2\left(1 - \frac{\Delta}{Z}\right) \tag{1-30}$$

命题 1.3和 1.4的证明分别见附录 B.3和 B.4。

1.3.3.3　收敛性结果

然后，我们可以得出使用 Cross-Entropy 损失函数时关于含噪声数据集的 SFL 收敛性的主要结果。此处沿用中的证明路径和定义，由于篇幅限制，省略了详细证明。

定理 1.3：SFL-V1 的收敛性（Cross-Entropy）

一般凸情形：: 在假设 1.1–1.4 以及 Cross-Entropy 损失函数下，若 $\eta^r \leqslant \frac{1}{2S\kappa}$,

$$\begin{aligned}\mathbb{E}\left[f\left(\boldsymbol{\omega}^R\right)\right] - f^* \leqslant & \frac{S\left\|\boldsymbol{\omega}^0 - \boldsymbol{\omega}^*\right\|^2}{2(R+1)} \\ & + O\left(\left(\frac{(\kappa^2 + \tilde{\kappa})^2\left\|\boldsymbol{\omega}^0 - \boldsymbol{\omega}^*\right\|^2 N}{\kappa_{min}^2(R+1)}\sum_{n=1}^{N} a_n^2\left(\sigma_n^2 + G^2 + H_3^2 + H_4^2\right)\right)^{\frac{1}{2}}\right) \\ & + O\left(\left(\frac{(\kappa^2 + \tilde{\kappa})^2 S\left\|\boldsymbol{\omega}^0 - \boldsymbol{\omega}^*\right\|^2}{\kappa_{min}^2(R+1)}\sum_{n=1}^{N} a_n\left(\sigma_n^2 + G^2 + H_3^2 + H_4^2\right)\right)^{\frac{1}{3}}\right).\end{aligned} \tag{1-31}$$

非凸情形下: 在假设 1.1–1.4 以及 Cross-Entropy 损失函数下，若 $\eta^r \leqslant$

$\min\left\{\frac{1}{16S\kappa}, \frac{1}{8SN\kappa\sum_{n=1}^{N}a_n^2}\right\}$,

$$\frac{1}{R}\sum_{r=0}^{R-1}\eta^r\mathbb{E}\left[\|\nabla_{\boldsymbol{\omega}}f\left(\boldsymbol{\omega}^r\right)\|^2\right] \leqslant \frac{4}{R\kappa_{min}}\left(f\left(\boldsymbol{\omega}^0\right)-f(\omega^*)\right) + O\left(\frac{NS(\kappa^2+\tilde{\kappa}^2)}{R\kappa_{min}}\sum_{n=1}^{N}(a_n^2+1)\left(\phi_n^2+\lambda^2+H_3^2\right)\sum_{R=0}^{R-1}(\eta^r)^2\right). \tag{1-32}$$

定理 1.4：SFL-V2 的收敛性（Cross-Entropy）

一般凸情形：: 在假设 1.1–1.4 以及 Cross-Entropy 损失函数下，若 $\eta^r \leqslant \frac{1}{2S\kappa}$,

$$\mathbb{E}\left[f\left(\boldsymbol{\omega}^R\right)\right]-f^* \leqslant \frac{S\left\|\boldsymbol{\omega}^0-\boldsymbol{\omega}^*\right\|^2}{2(R+1)} + O\left(\left(\frac{\left\|\boldsymbol{\omega}^0-\boldsymbol{\omega}^*\right\|^2 N}{(R+1)}\sum_{n=1}^{N}a_n^2\left(\sigma_n^2+G^2+H_3^2+H_4^2\right)\right)^{\frac{1}{2}}\right) + O\left(\left(\frac{S\left\|\boldsymbol{\omega}^0-\boldsymbol{\omega}^*\right\|^2}{(R+1)}\sum_{n=1}^{N}a_n\left(\sigma_n^2+G^2+H_3^2+H_4^2\right)\right)^{\frac{1}{3}}\right). \tag{1-33}$$

非凸情形下: 在假设 1.1–1.4 以及 Cross-Entropy 损失函数下，若 $\eta^r \leqslant \min\left\{\frac{1}{16S\kappa}, \frac{1}{8SN^2\kappa}\right\}$，则：

$$\frac{1}{R}\sum_{r=0}^{R-1}\eta^r\mathbb{E}\left[\|\nabla_{\boldsymbol{\omega}}f\left(\boldsymbol{\omega}^r\right)\|^2\right] \leqslant \frac{4}{R\kappa}\left(f\left(\boldsymbol{\omega}^0\right)-f(\omega^*)\right) + O\left(\frac{NS\kappa}{R}\sum_{n=1}^{N}(a_n^2+1)\left(\phi_n^2+\lambda^2+H_3^2\right)\sum_{R=0}^{R-1}(\eta^r)^2\right). \tag{1-34}$$

收敛速率的上界随着客户端噪声方差 $O(\delta^2)$ 的增加而增大。这从理论上刻画了在交叉熵损失下，标签噪声如何减缓分割-联邦学习的收敛速度。对于分类问题，标签噪声的影响随噪声率 δ 呈二次方增长（即 $O(\delta^2)$）。当噪声率较低时，系统可能具备一定的鲁棒性；然而，随着噪声率的增加，其负面影响会显著加剧。这使得在含噪数据上训练的模型越来越难以从干净的数据分布中学习到底层的真实模式。

1.4　SFL 收敛性的实验验证

1.4.1　实验设置

1.5　实验设置

为了验证 SFL 算法的收敛性，本文在 CIFAR-10 和 CIFAR-100 两个基准数据集上开展了实验。所有实验均采用 Cross-Entropy 作为损失函数。

除非另有说明，本地训练轮数统一设定为 $E = 5$。关于参与客户端的数量 N，我们在不同实验场景中进行了差异化设置：在章节 1.5.1和 1.5.2中，设定 $N = 10$；在章节 1.5.3中，设定 $N = 100$ 。

为模拟真实的 non-IID 数据，我们采用广泛使用的 Dirichlet 分布[?] 对数据进行划分，并引入浓度参数 α 进行控制。α 值越小，表示客户端间的数据分布差异越大。

在模型架构方面，我们选用 ResNet-18 作为骨干网络，该网络由四个残差块（Residual Blocks）组成。所有实验均在仿真环境下进行，硬件平台配置为 Intel(R) Xeon(R) Gold 5320 CPU (@ 2.20GHz) 搭配 NVIDIA A100-PCIE-80GB GPU。

1.5.1　超参数对模型收敛性的影响

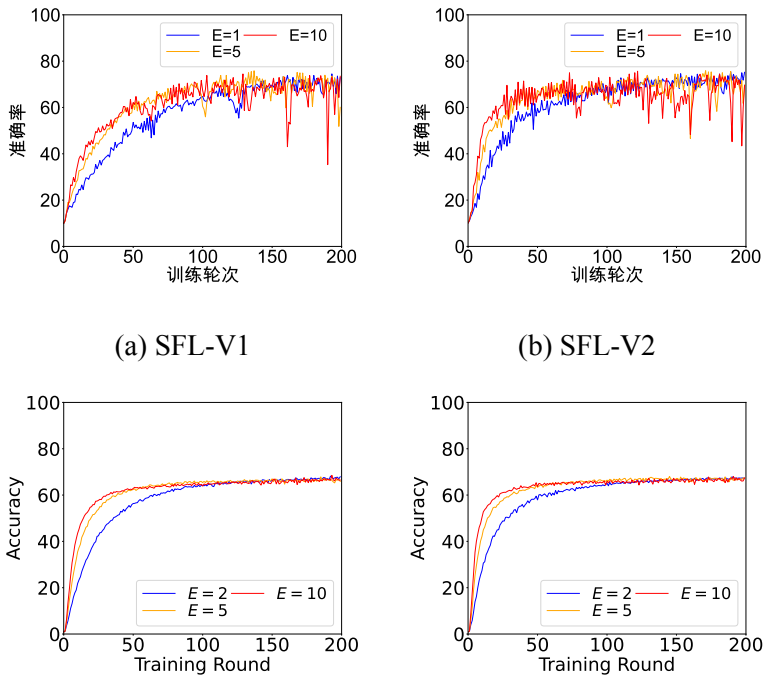

(a) SFL-V1　(b) SFL-V2

(c) SFL-V1　(d) SFL-V2

图 1-2　每轮训练数据迭代次数 E 对模型准确率的影响

在 SFL 中，各类超参数都会对于模型的收敛产生影响，本部分实验目标是验

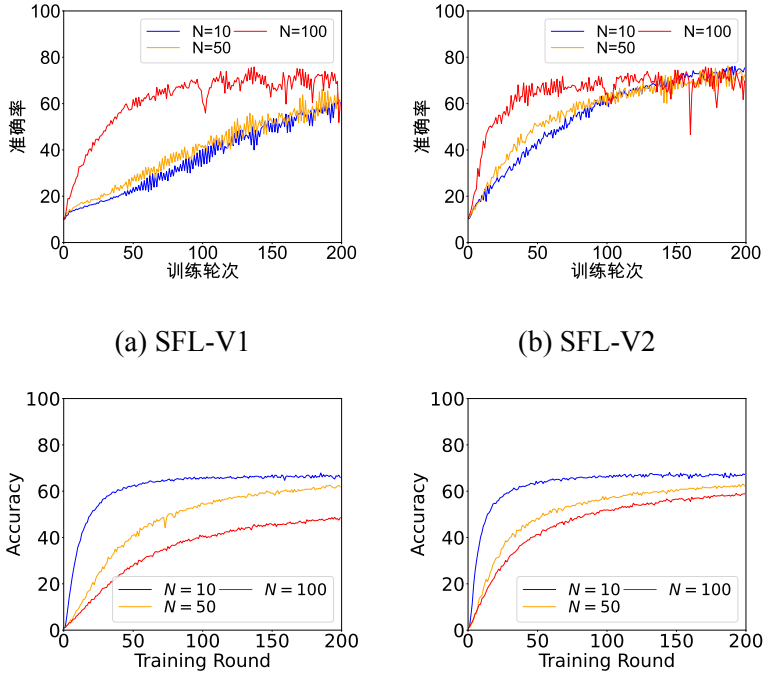

(a) SFL-V1　　(b) SFL-V2

(c) SFL-V1　　(d) SFL-V2

图 1-3　参与训练的用户数 N 对模型准确率的影响

证 SFL 在不同超参数下的收敛规律，包含 SFL-V1 和 SFL-V2 两个算法。

本地训练迭代次数 E 是 SFL 中的关键超参数。通常情况下，E 值过小会导致本地模型在未充分提取特征时即被聚合，造成有效信息的丢失（欠拟合）；反之，E 值过大则易引发本地过拟合，阻碍联邦服务器聚合出具有良好泛化性能的全局模型。为此，本试验设定 $E \in \{2, 5, 10\}$ 开展对比实验。由图 1-2 所示，在 CIFAR-10 和 CIFAR-100 上，SFL-V1 和 SFL-V2 均呈现相同趋势：E 的变化几乎不改变最终准确率，但增大 E 在加速收敛的同时，也加剧了准确率的震荡。

参与训练的用户数量 N 对模型的收敛过程也具有显著影响。当 N 较小时，单个用户的本地更新在全局聚合中占据较高权重，这虽有助于提升全局模型在参与用户上的泛化性能，但也使得全局模型易受个别低质量本地模型的干扰，导致训练稳定性下降。反之，当 N 较大时，单个用户的权重被稀释，虽然降低了异常值对全局模型的负面影响，但也会削弱模型对特定用户分布的适应能力。为此，本试验设定 $N \in \{10, 50, 100\}$ 进行对比实验。如图 1-3 所示，在 CIFAR-10 和 CIFAR-100 上，SFL-V1 和 SFL-V2 均呈现相同趋势：即 N 的变化几乎不改变模型最终准确率，但 N 的增加会导致模型收敛速度放缓。

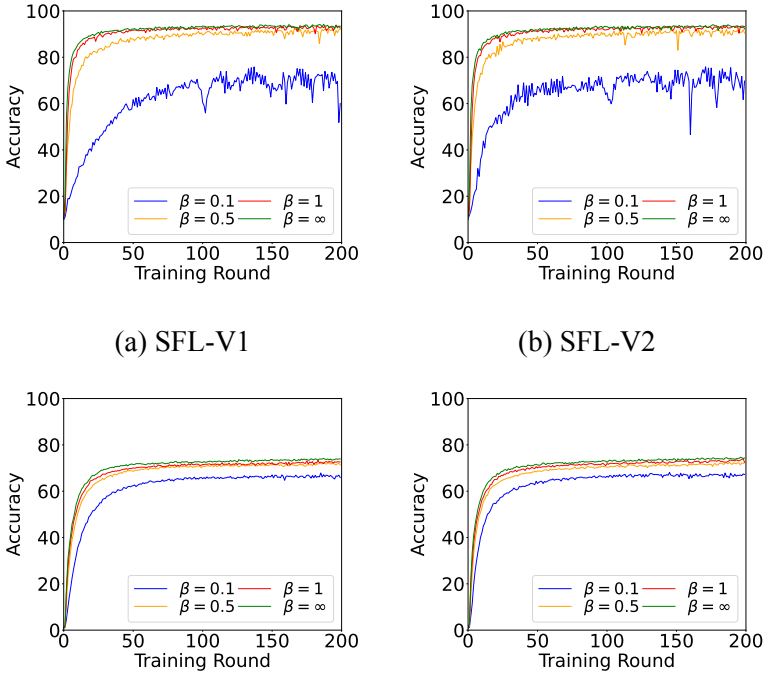

(a) SFL-V1　(b) SFL-V2

(c) SFL-V1　(d) SFL-V2

图 1-4　Non-IID 数据对模型准确率的影响

1.5.2　Non-IID 数据对模型收敛性的影响

本节实验专注于验证非独立同分布（Non-IID）数据对分割联邦学习（SFL）模型收敛性的影响。为了量化数据分布的不均匀程度，我们引入了狄利克雷分布参数 α（在部分文献及本实验图示中记为 β），并设置了 $\alpha \in \{0.1, 0.5, 1, \infty\}$ 四种典型数据场景。其中，$\alpha \to \infty$ 代表理想的全局独立同分布（IID）状态，而 $\alpha = 0.1$ 则对应极度不平衡的 Non-IID 分布。我们在 CIFAR-10 和 CIFAR-100 数据集上分别考察了 SFL-V1 和 SFL-V2 两种架构的表现。

从理论层面分析，Non-IID 数据会导致各客户端本地模型产生显著的统计偏移（Statistical Shift），这种偏移破坏了全局模型聚合时的梯度一致性，进而阻碍收敛。图 1-4 的实验结果有力地证实了这一假设，并揭示了 α 值对模型收敛性能的严格制约关系：

- **收敛速率显著减缓：**如图所示，随着 α 值的减小（从 ∞ 降至 0.1），模型达到稳定准确率所需的训练轮次（Training Rounds）明显增加。在 $\alpha = 0.1$ 的极端场景下，曲线爬升缓慢，表明模型需要更多的通信迭代才能克服本地数据的偏差。
- **最终性能下降：**不同 α 设置下的收敛上限存在显著差异。IID 场景（$\alpha = \infty$）下模型能达到最高的测试准确率，而随着数据分布趋于不均匀，最终收敛精度呈现阶梯式下降，特别是在 $\alpha = 0.1$ 时，性能损失最为严重。

• **训练过程震荡加剧：**观察训练轨迹可以发现，低 α 值对应的曲线波动幅度（Oscillation Amplitude）显著大于高 α 值场景。这是由于在高度 Non-IID 分布下，各客户端计算的梯度方向差异巨大，导致服务器端聚合后的全局模型更新方向不稳定，从而引发剧烈的准确率震荡。

综上所述，实验结果表明 Non-IID 数据严重阻碍了 SFL 模型的收敛效率与最终性能，且数据分布的不均匀程度（由 α 表征）与该抑制作用呈强负相关：α 越小，数据异构性越强，模型收敛越困难。

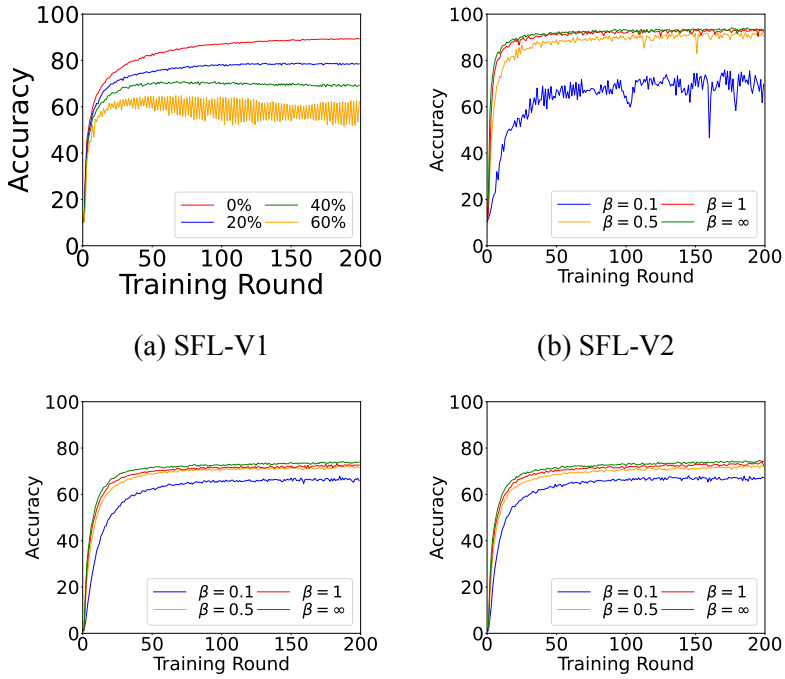

(a) SFL-V1　(b) SFL-V2

(c) SFL-V1　(d) SFL-V2

图 1-5　Non-IID 数据对模型准确率的影响

1.5.3　标签噪声对模型收敛性的影响

在本试验中，我们旨在 non-IID 数据（$\alpha = 0.1$）和 IID 数据（$\alpha = \infty$）下验证定理 **??–??**。为此，我们考虑两种情形：(1) 60% 的客户端存在标签噪声（部分含噪）；(2) 所有客户端均存在标签噪声（全部含噪）。

图 1-5 与图 1-7 分别展示了 SFL-V2 在 CIFAR-10 和 CIFAR-100 数据集上的训练轨迹。在各图中，不同曲线对应不同的噪声率。基于上述图表，我们得出以下几点观察：首先，在大多数情况下，随着训练轮数的增加，准确率呈现出明显的拐点：在该点之前迅速上升，随后趋于平稳。其次，非 IID 数据与标签噪声均会减缓模型收敛，表现为拐点的延迟出现。且噪声率越高，该效应愈发显著（例如，见图 1-7(c)）。这一现象与定理 **??–??** 中的理论分析相吻合。第三，较高的标签噪声

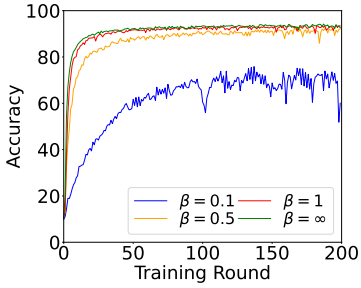

(a) SFL-V1

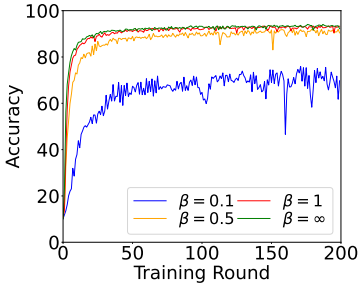

(b) SFL-V2

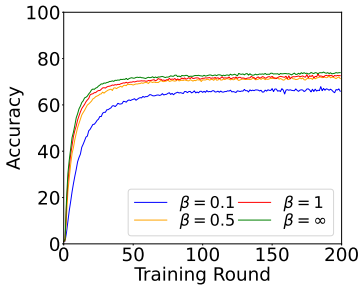

(c) SFL-V1

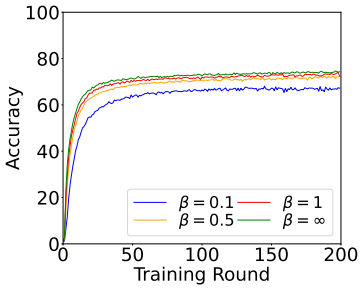

(d) SFL-V2

图 1-6　Non-IID 数据对模型准确率的影响

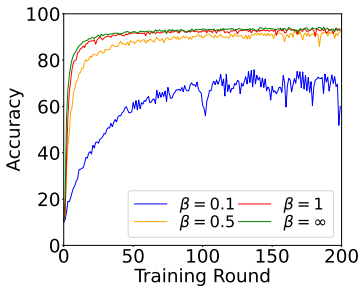

(a) SFL-V1

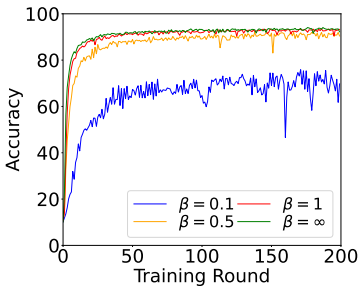

(b) SFL-V2

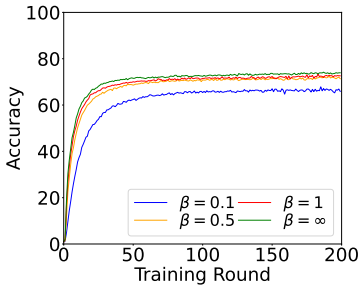

(c) SFL-V1

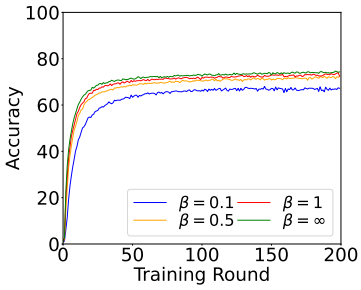

(d) SFL-V2

图 1-7　Non-IID 数据对模型准确率的影响

率会使模型更倾向于过拟合噪声标签（例如，见图 1-5(b)）。第四，非 IID 数据与标签噪声均会显著降低最终模型的准确率。

附录 A

A.1 引理1.1的证明

引理 3.1（收敛性分析中的模型拆分）：通过分割-联邦学习训练得到的模型与最优模型之间的性能差距上界如下：

$$\mathbb{E}\left[f(\boldsymbol{\omega}^R)\right]-f(\boldsymbol{\omega}^*)\leqslant\frac{S}{2}\left(\mathbb{E}||\boldsymbol{\omega}_{\mathrm{s}}^R-\boldsymbol{\omega}_{\mathrm{s}}^*||^2+\mathbb{E}||\boldsymbol{\omega}_{\mathrm{c}}^R-\boldsymbol{\omega}_{\mathrm{c}}^*||^2\right). \tag{xxx}$$

证明：由于 F_n 是 S-光滑的，容易证明全局损失函数 $f(\cdot)$ 也是 S-光滑的。因此，我们有

$$\mathbb{E}\left[f(\boldsymbol{\omega}^R)\right]-f(\boldsymbol{\omega}^*)\leqslant\mathbb{E}\left[\langle\boldsymbol{\omega}^R-\boldsymbol{\omega}^*,\nabla f(\boldsymbol{\omega}^*)\rangle\right]+\frac{S}{2}\mathbb{E}\left[||\boldsymbol{\omega}^R-\boldsymbol{\omega}^*||^2\right]=\frac{S}{2}\mathbb{E}\left[||\boldsymbol{\omega}^R-\boldsymbol{\omega}^*||^2\right]. \tag{A-1}$$

由于 $\boldsymbol{\omega}^R\triangleq[\boldsymbol{\omega}_c^R;\boldsymbol{\omega}_s^R]$，且 $\boldsymbol{\omega}^*\triangleq[\boldsymbol{\omega}_c^*;\boldsymbol{\omega}_s^*]$，我们可得

$$\begin{aligned}&\mathbb{E}\left[||\boldsymbol{\omega}^R-\boldsymbol{\omega}^*||^2\right]=\mathbb{E}\left[||[\boldsymbol{\omega}_c^R;\boldsymbol{\omega}_s^R]-[\boldsymbol{\omega}_c^*;\boldsymbol{\omega}_s^*]||^2\right]\\&=\mathbb{E}\left[||[\boldsymbol{\omega}_c^R-\boldsymbol{\omega}_c^*;\boldsymbol{\omega}_s^R-\boldsymbol{\omega}_s^*]||^2\right]=\mathbb{E}\left[||\boldsymbol{\omega}_c^R-\boldsymbol{\omega}_c^*||^2\right]+\mathbb{E}\left[||\boldsymbol{\omega}_s^R-\boldsymbol{\omega}_s^*||^2\right].\end{aligned} \tag{A-2}$$

将 A-2 代入 A-1，即完成证明。 ■

A.2 引理1.2的证明

引理 3.2（带标签噪声的 MSE）：

$$F_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right)=F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right)+\frac{1}{|\zeta_n^{noi}|}\sum_{(x_i,\tilde{y}_i)\in\zeta_n^{noi}}\left(\epsilon_i^2-2\left(h\left(x_i;\boldsymbol{\omega}\right)-y_i\right)\epsilon_i\right). \tag{xxx}$$

证明：

$$\begin{aligned}F_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right)&=\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}\left(h\left(x_j;\boldsymbol{\omega}\right)-\left(y_j+\epsilon_j\right)\right)^2\\&=\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}\left(\left(h\left(x_j;\boldsymbol{\omega}\right)-y_j\right)-\epsilon_j\right)^2\\&=\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}\left(\left(h\left(x_j;\boldsymbol{\omega}\right)-y_j\right)^2-2\left(h\left(x_j;\boldsymbol{\omega}\right)-y_j\right)\epsilon_j+\epsilon_j^2\right)\end{aligned} \tag{A-3}$$

■

A.3 引理1.3的证明

引理 3.3（标签噪声下 MSE 的随机梯度）：

$$\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right) = \boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right) - \frac{1}{|\zeta_n^{noi}|} \sum_{(x_i, y_i+\epsilon_i)\in\zeta_n^{noi}} 2\epsilon_i \nabla h\left(x_i; \boldsymbol{\omega}\right). \quad \text{(xxx)}$$

证明：

$$\begin{aligned}
\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right) &= \nabla_\omega F_n\left(\boldsymbol{\omega}; \zeta_n^{noi}\right) \\
&= \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, y_j+\epsilon_j\right)\in\zeta_n^{noi}} \nabla_\omega \left(h\left(x_j; \boldsymbol{\omega}\right) - \left(y_j + \epsilon_j\right)\right)^2 \\
&= \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, y_j+\epsilon_j\right)\in\zeta_n^{noi}} \nabla_\omega \left(\left(h\left(x_j; \boldsymbol{\omega}\right) - y_j\right)^2 - 2\left(h\left(x_j; \boldsymbol{\omega}\right) - y_j\right)\epsilon_j + \epsilon_j^2\right) \\
&= \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, y_j+\epsilon_j\right)\in\zeta_n^{noi}} \nabla_\omega \left(h\left(x_j; \boldsymbol{\omega}\right) - y_j\right)^2 \\
&- \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, y_j+\epsilon_j\right)\in\zeta_n^{noi}} \nabla_\omega \left(2\epsilon_j\left(h\left(x_j; \boldsymbol{\omega}\right) - y_j\right) - \epsilon_j^2\right) \\
&= \boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right) - \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, y_j+\epsilon_j\right)\in\zeta_n^{noi}} \nabla_\omega \left(2\epsilon_j\left(h\left(x_j; \boldsymbol{\omega}\right) - y_j\right) - \epsilon_j^2\right) \\
&= \boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right) - \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, y_j+\epsilon_j\right)\in\zeta_n^{noi}} 2\epsilon_j \nabla_\omega h\left(x_j; \boldsymbol{\omega}\right)
\end{aligned} \tag{A-4}$$

■

A.4 均方差损失下含标签噪声的随机梯度的方差

命题 1.1（均方差损失下含标签噪声的随机梯度的方差）：在假设 1.1 下，任意客户端 $n \in \mathcal{N}$ 在噪声小批量上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)$ 的期望方差是有界的：

$$\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right) - \nabla F_n^{noi}\left(\boldsymbol{\omega}\right)\right\|^2\right] \leqslant \phi_n^2 + H_1^2, \tag{A-5}$$

其中 H_1^2 定义为：

$$\begin{aligned}
H_1^2 = &\frac{8\sigma^2}{|\mathcal{D}_n^{noi}|^2} \sum_{(x_i, y_i+\epsilon_i)\in\mathcal{D}_n^{noi}} \left(\nabla_\omega h\left(x_i; \boldsymbol{\omega}\right)\right)^2 \\
&+ \frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|} \sum_{(x_i, y_i+\epsilon_i)\in\mathcal{D}_n^{noi}} \left(\nabla_\omega h\left(x_i; \boldsymbol{\omega}\right)\right)^2
\end{aligned} \quad \text{(xxx)}$$

证明：为了推导和表述的简洁性，我们将

$$\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}(\boldsymbol{\omega})\|^2]$$

转换为

$$\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}(\boldsymbol{\omega})\|^2],$$

其中 $\epsilon\sim\mathcal{N}(\mu,\sigma^2)$ 表示随机噪声。这种转换是等价的，因为任意数据样本中的随机噪声 ϵ 与干净数据 (x,y) 是相互独立的。同时我们记 $|\zeta_n^{noi}|=|\zeta_n^{cle}|=|\zeta_n|$ 且 $|\mathcal{D}_n^{noi}|=|\mathcal{D}_n^{cle}|=|\mathcal{D}_n|$。

根据公式 (xxx)，我们有

$$\begin{aligned}
&\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}\left(\boldsymbol{\omega}\right)\right\|^2\right]\\
&\quad=\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\Bigg[\Bigg\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\frac{1}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\zeta_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\\
&\qquad-\left(\boldsymbol{\nabla}F_n^{cle}\left(\boldsymbol{\omega}\right)-\frac{1}{|\mathcal{D}_n|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\right)\Bigg\|^2\Bigg].
\end{aligned}\tag{A-6}$$

令 $L_n^{noi}\triangleq\frac{1}{|\mathcal{D}_n|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)-\frac{1}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\zeta_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)$。则公式 (A-6) 可表示为

$$\begin{aligned}
&\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\boldsymbol{\nabla}F_n^{cle}\left(\boldsymbol{\omega}\right)-L_n^{noi}\|^2\right]\\
&\quad=\mathbb{E}_{\zeta_n^{cle}}\left[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\boldsymbol{\nabla}F_n^{cle}\left(\boldsymbol{\omega}\right)\|^2\right]+\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\|L_n^{noi}\|^2\right]\\
&\qquad+\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[2\langle\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\boldsymbol{\nabla}F_n^{cle}\left(\boldsymbol{\omega}\right),L_n^{noi}\rangle\right].
\end{aligned}\tag{A-7}$$

在公式 (A-7) 中，第一项根据假设 1.1 小于 ϕ_n^2；第三项由于干净数据与噪声相互独立而等于零；第二项可表示为

$$\begin{aligned}
&\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\|L_n^{noi}\|^2\right]\\
&=\mathbb{E}_{\epsilon}\left[\left\|\frac{1}{|\mathcal{D}_n|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\right\|^2\right]\\
&\quad+\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\|\frac{1}{|\zeta_n|}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}2\epsilon_j\boldsymbol{\nabla}h\left(x_j;\boldsymbol{\omega}\right)\right\|^2\right]
\end{aligned}$$

$$+\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\frac{1}{|\mathcal{D}_n|}\frac{1}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}\right.$$

$$\left.4\epsilon_i\epsilon_j\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\boldsymbol{\nabla}h\left(x_j;\boldsymbol{\omega}\right)\right]. \tag{A-8}$$

在公式 (A-8) 中，基于小批量随机采样，第一项与最后一项之和等于

$$\frac{8\sigma^2}{|\mathcal{D}_n^{noi}|^2}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}\left(\boldsymbol{\nabla}_{\omega}h\left(x_i;\boldsymbol{\omega}\right)\right)^2,$$

中间项等于

$$\frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}\left(\boldsymbol{\nabla}_{\omega}h\left(x_i;\boldsymbol{\omega}\right)\right)^2.$$

将公式 (A-8) 代入 (A-7)，即完成证明。若对任意 $\left(x_j,y_j+\epsilon_j\right)\in\mathcal{D}_n$ 都有 $\epsilon_j=0$，该分析依然成立。 ■

A.5 均方差损失下含标签噪声的随机梯度的平方的期望

命题 1.2（均方差损失下含标签噪声的随机梯度的平方的期望）：在假设 1.2 下，任意客户端 $n\in\mathcal{N}$ 在噪声数据集 $\mathcal{D}_n^{noi}$ 上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)$ 是有界的，即：

$$\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)\right\|^2\right]\leqslant G_n^2+H_2^2, \tag{A-9}$$

其中 H_2^2 定义为：

$$H_2^2=\sum_{\zeta_n^{noi}\subset\mathcal{D}_n^{noi}}\frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}\left(\boldsymbol{\nabla}_{\omega}h\left(x_j;\boldsymbol{\omega}\right)\right)^2 \tag{}$$

证明：为简化推导，我们将

$$\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}[\|\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n^{noi})\|^2]$$

表示为 $\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}[\|\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n^{noi})\|^2]$，其中 $\epsilon\sim\mathcal{N}(\mu,\sigma^2)$ 表示任意噪声，$\zeta_n^{cle}\sim\mathcal{D}_n^{cle}$，此为等价变换。

根据公式 (1-12)，我们有

$$\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)\right\|^2\right]=\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)\|^2\right]$$

$$-\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\langle\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right),\frac{4}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\zeta_n^{noi}}\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\right\rangle\right]$$

$$+\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\|\frac{2}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\zeta_n^{noi}}\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\right\|^2\right]. \quad \text{(A-10)}$$

第一项基于假设 1.2 被 G_n^2 所限制；第二项由于噪声 ϵ_i 与数据 (x_i, y_i) 相互独立而等于零；由于小批量随机采样，第三项等于

$$\sum_{\zeta_n^{noi}\subset\mathcal{D}_n^{noi}}\frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}\left(\boldsymbol{\nabla}_{\omega}h\left(x_j;\boldsymbol{\omega}\right)\right)^2.$$

由此完成证明。若对任意 $\left(x_j, y_j+\epsilon_j\right)\in\mathcal{D}_n$ 都有 $\epsilon_j=0$，该分析依然成立。 ■

附录 B

B.1 引理1.4的证明

引理 3.4（带标签噪声的 Cross Entropy）：

$$F_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right) = F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right) + \frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} r_j\left(-log\left(\frac{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}\right)\right) \quad \text{(B-1)}$$

证明：

$$\begin{aligned}
F_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right) &= \frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} -log\left(M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)\right) \\
&= \frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}}\left(-log\left(M\left(x_j,y_j;\boldsymbol{\omega}\right)\right) - log\left(\frac{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}\right)\right) \\
&= F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right) + \frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} r_j\left(-log\left(\frac{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}\right)\right)
\end{aligned} \quad \text{(B-2)}$$

■

B.2 引理1.4的证明

引理 3.5（标签噪声下 Cross Entropy 的随机梯度）：

$$F_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right) = \boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right) + \frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right) \quad \text{(B-3)}$$

证明：

$$
\begin{aligned}
& g_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right) \\
&= \boldsymbol{\nabla}_\omega F_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right) \\
&= \boldsymbol{\nabla}_\omega\left(F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right)+\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} r_j\left(-log\left(\frac{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}\right)\right)\right) \\
&= \boldsymbol{\nabla}_\omega\left(F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right)\right)+\boldsymbol{\nabla}_\omega\left(\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} r_j\left(-log\left(\frac{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}\right)\right)\right) \\
&= \boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)+\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right)
\end{aligned}
\tag{B-4}
$$

■

B.3

命题 1.3（Cross-Entorpy 损失下含标签噪声的随机梯度的方差）：在假设 1.1 下，任意客户端 $n\in\mathcal{N}$ 在噪声小批量上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)$ 的期望方差是有界的：

$$
\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}\left(\boldsymbol{\omega}\right)\right\|^2\right]\leqslant\phi_n^2+H_3^2, \tag{xxx}
$$

其中 H_3^2 定义为：

$$
H_3^2=4\delta\left(\frac{\Delta}{Z}+\frac{3\Delta}{D}\right)+4\delta^2\left(4-\frac{\Delta}{Z}-\frac{3\Delta}{D}\right) \tag{xxx}
$$

证明：为了推导和表述的简洁性，我们将

$$
\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}(\boldsymbol{\omega})\|^2]
$$

转换为

$$
\mathbb{E}_r\mathbb{E}_{\zeta_n^{cle}}[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}(\boldsymbol{\omega})\|^2],
$$

其中 $r\sim$ Bernoulli(δ) 表示随机噪声。这种转换是等价的，因为任意数据样本中的随机噪声 r 与干净数据 (x,y) 是相互独立的。沿用前述记号，我们设 $|\zeta_n^{noi}|=|\zeta_n^{cle}|=|\zeta_n|$ 且 $|\mathcal{D}_n^{noi}|=|\mathcal{D}_n^{cle}|=|\mathcal{D}_n|$。

根据公式 (B-3)，我们有

$$
\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}_\omega F_n^{noi}\left(\boldsymbol{\omega}\right)\right\|^2\right]
$$

$$
\begin{aligned}
&= \mathbb{E}_r \mathbb{E}_{\zeta_n^{cle} \sim \mathcal{D}_n^{cle}} \left[\left\| \boldsymbol{g}_n \left(\boldsymbol{\omega}, \zeta_n^{noi} \right) - \boldsymbol{\nabla}_\omega F_n^{noi} \left(\boldsymbol{\omega} \right) \right\|^2 \right] \\
&= \mathbb{E}_r \mathbb{E}_{\zeta_n^{cle} \sim \mathcal{D}_n^{cle}} \left[\| \boldsymbol{g}_n \left(\boldsymbol{\omega}, \zeta_n^{cle} \right) - \boldsymbol{\nabla}_\omega F_n^{cle} \left(\boldsymbol{\omega} \right) \|^2 \right] \\
&+ \mathbb{E}_r \mathbb{E}_{\zeta_n^{cle} \sim \mathcal{D}_n^{cle}} \left[\| \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \zeta_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) \right. \\
&\left. - \frac{1}{|\mathcal{D}_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \mathcal{D}_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) \| ^2 \right] \\
&+ \mathbb{E}_r \mathbb{E}_{\zeta_n^{cle} \sim \mathcal{D}_n^{cle}} 2 < \boldsymbol{g}_n \left(\boldsymbol{\omega}, \zeta_n^{cle} \right) - \boldsymbol{\nabla}_\omega F_n^{cle} \left(\boldsymbol{\omega} \right), \\
&\frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \zeta_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) \\
&- \frac{1}{|\mathcal{D}_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \mathcal{D}_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) >
\end{aligned}
\tag{B-5}
$$

在公式 (B-5) 中，第一项根据假设 1.1 小于 ϕ_n^2；第二项可表示为：

$$
\begin{aligned}
&\mathbb{E}_r \mathbb{E}_{\zeta_n \sim \mathcal{D}_n} \left[\| \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \zeta_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) \right. \\
&\left. - \frac{1}{|\mathcal{D}_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \mathcal{D}_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) \| ^2 \right] \\
&= \mathbb{E}_r \mathbb{E}_{\zeta_n^{cle} \sim \mathcal{D}_n} \left[\| \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \zeta_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) \| ^2 \right. \\
&+ \| \frac{1}{|\mathcal{D}_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \mathcal{D}_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) \| ^2 \\
&- 2 < \frac{1}{|\zeta_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \zeta_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right), \\
&\left. \frac{1}{|\mathcal{D}_n^{noi}|} \sum_{\left(x_j, \hat{y}_j\right) \in \mathcal{D}_n^{noi}} r_j \left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, y_j; \boldsymbol{\omega} \right)}{M \left(x_j, y_j; \boldsymbol{\omega} \right)} - \frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}} M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)}{M \left(x_j, \hat{y}_j; \boldsymbol{\omega} \right)} \right) > \right]
\end{aligned}
$$

$$\leqslant \frac{2e\left(\phi_{max}-\phi_{min}\right)}{|\zeta_n^{noi}|}+\frac{2e^2\left(\phi_{max}-\phi_{min}\right)\left(|\zeta_n^{noi}|^2-|\zeta_n^{noi}|\right)}{|\zeta_n^{noi}|^2}$$
$$+\frac{2e\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|}+\frac{2e^2\left(\phi_{max}-\phi_{min}\right)\left(|\mathcal{D}_n^{noi}|^2-|\mathcal{D}_n^{noi}|\right)}{|\mathcal{D}_n^{noi}|^2}$$
$$+\frac{4e\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|}+\frac{4\left(|\mathcal{D}_n^{noi}|-1\right)e^2\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|} \tag{B-6}$$

第三项可表示为：

$$\mathbb{E}_r\mathbb{E}_{\zeta_n\sim\mathcal{D}_n}\Bigg[-2<\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\boldsymbol{\nabla}_\omega F_n^{cle}\left(\boldsymbol{\omega}\right),$$
$$\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right)$$
$$-\frac{1}{|\mathcal{D}_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\mathcal{D}_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right)>\Bigg]$$
$$=\mathbb{E}_r\mathbb{E}_{\zeta_n\sim\mathcal{D}_n}\Bigg[-2<\frac{1}{|\zeta_n^{cle}|}\sum_{\left(x_j,y_j\right)\in\zeta_n^{cle}}-\frac{\boldsymbol{\nabla}_\omega\left(M\left(x_j,y_j;\boldsymbol{\omega}\right)\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}$$
$$-\frac{1}{|\mathcal{D}_n^{cle}|}\sum_{\left(x_j,y_j\right)\in\mathcal{D}_n^{cle}}-\frac{\boldsymbol{\nabla}_\omega\left(M\left(x_j,y_j;\boldsymbol{\omega}\right)\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)},$$
$$\frac{1}{|\zeta_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\zeta_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right)$$
$$-\frac{1}{|\mathcal{D}_n^{noi}|}\sum_{\left(x_j,\hat{y}_j\right)\in\mathcal{D}_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right)>\Bigg]$$
$$\leqslant \frac{2e\left(\phi_{max}-\phi_{min}\right)}{|\zeta_n^{noi}|}+\frac{2e^2\left(\phi_{max}-\phi_{min}\right)\left(|\zeta_n^{noi}|^2-|\zeta_n^{noi}|\right)}{|\zeta_n^{noi}|^2}$$
$$+\frac{2e\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|}+\frac{2e^2\left(\phi_{max}-\phi_{min}\right)\left(|\mathcal{D}_n^{noi}|^2-|\mathcal{D}_n^{noi}|\right)}{|\mathcal{D}_n^{noi}|^2}$$
$$+\frac{4e\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|}+\frac{4\left(|\mathcal{D}_n^{noi}|-1\right)e^2\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|} \tag{B-7}$$

将公式 (B-6) 和 (B-7) 代入 (B-5)，可以得到：

$$
\begin{aligned}
&\mathbb{E}_r\mathbb{E}_{\zeta_n\sim\mathcal{D}_n}\left[\|\frac{1}{|\zeta_n^{noi}|}\sum_{(x_j,\hat{y}_j)\in\zeta_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right)\right.\\
&\leqslant\frac{4e\left(\phi_{max}-\phi_{min}\right)}{|\zeta_n^{noi}|}+\frac{4e^2\left(\phi_{max}-\phi_{min}\right)\left(|\zeta_n^{noi}|^2-|\zeta_n^{noi}|\right)}{|\zeta_n^{noi}|^2}\\
&+\frac{4e\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|}+\frac{4e^2\left(\phi_{max}-\phi_{min}\right)\left(|\mathcal{D}_n^{noi}|^2-|\mathcal{D}_n^{noi}|\right)}{|\mathcal{D}_n^{noi}|^2}\\
&+\frac{8e\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|}+\frac{8\left(|\mathcal{D}_n^{noi}|-1\right)e^2\left(\phi_{max}-\phi_{min}\right)}{|\mathcal{D}_n^{noi}|}\\
&=4\delta\left(\frac{\Delta}{Z}+\frac{3\Delta}{D}\right)+4\delta^2\left(4-\frac{\Delta}{Z}-\frac{3\Delta}{D}\right)
\end{aligned}
\tag{B-8}
$$

若对任意 $\left(x_j,\hat{y}_j\right)\in\mathcal{D}_n$ 都有 $\hat{y}_j=y_j$，该分析依然成立。 ■

B.4

命题 1.4（Cross-Entorpy 损失下含标签噪声的随机梯度的平方的期望）：在假设 1.2 下，任意客户端 $n\in\mathcal{N}$ 在噪声数据集 $\mathcal{D}_n^{noi}$ 上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)$ 是有界的，即：

$$\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)\right\|^2\right]\leqslant G_n^2+H_4^2, \tag{xxx}$$

其中 H_4^2 定义为：

$$H_4^2=4\delta\frac{\Delta}{Z}+4\delta^2\left(1-\frac{\Delta}{Z}\right) \tag{xxx}$$

证明：为简化推导，我们将

$$\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}[\|\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n^{noi})\|^2]$$

表示为 $\mathbb{E}_r\mathbb{E}_{\zeta_n^{cle}}[\|\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n^{noi})\|^2]$，其中 $r\sim\text{Bernoulli}(\delta)$ 表示随机噪声。
根据公式 (B-3)，我们有

$$
\begin{aligned}
&\mathbb{E}r\mathbb{E}\zeta_n\sim\mathcal{D}n\left[\left\|\boldsymbol{g}n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)\right\|^2\right]\\
&\qquad=\mathbb{E}r\mathbb{E}\zeta_n\sim\mathcal{D}n\left[\left\|\boldsymbol{g}n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)\right\|^2\right]\\
&+\mathbb{E}r\mathbb{E}\zeta_n\sim\mathcal{D}n\left[\left\|\frac{1}{|\zeta_n^{noi}|}\sum\left(x_j,\hat{y}j\right)\in\zeta_n^{noi}r_j\left(\frac{\boldsymbol{\nabla}\boldsymbol{\omega}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla}_{\boldsymbol{\omega}}M\left(x_j,\hat{y}j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}j;\boldsymbol{\omega}\right)}\right)\right\|^2\right]\\
&\qquad+\mathbb{E}r\mathbb{E}\zeta_n\sim\mathcal{D}n\left[2<\frac{1}{|\zeta_n^{cle}|}\sum\left(x_j,y_j\right)\in\zeta_n^{cle}\frac{\boldsymbol{\nabla}_{\omega}\left(M\left(x_j,y_j;\boldsymbol{\omega}\right)\right)}{\left(M\left(x_j,y_j;\boldsymbol{\omega}\right)\right.},\right.
\end{aligned}
$$

$$\frac{1}{|\zeta_n^{noi}|}\sum_{(x_j,\hat{y}j)\in\zeta_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla\omega}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla_\omega}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right)\Bigg]$$

(B-9)

第一项基于假设 1.2 被 G_n^2 所限制；第二项可表示为：

$$\mathbb{E}r\mathbb{E}\zeta_n \sim \mathcal{D}n\left[\left\|\frac{1}{|\zeta_n^{noi}|}\sum\left(x_j,\hat{y}j\right)\in\zeta_n^{noi} r_j\left(\frac{\boldsymbol{\nabla\omega}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla_\omega}M\left(x_j,\hat{y}j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}j;\boldsymbol{\omega}\right)}\right)\right\|^2\right]$$
$$\leqslant\frac{2e\left(\phi_{max}-\phi_{min}\right)}{|\zeta_n^{noi}|}+\frac{2e^2\left(\phi_{max}-\phi_{min}\right)\left(|\zeta_n^{noi}|^2-|\zeta_n^{noi}|\right)}{|\zeta_n^{noi}|^2}$$

(B-10)

第三项可表示为：

$$\mathbb{E}r\mathbb{E}\zeta_n \sim \mathcal{D}n\Bigg[2<\frac{1}{|\zeta_n^{cle}|}\sum\left(x_j,y_j\right)\in\zeta_n^{cle}\frac{\boldsymbol{\nabla}_\omega\left(M\left(x_j,y_j;\boldsymbol{\omega}\right)\right)}{(M\left(x_j,y_j;\boldsymbol{\omega}\right)},$$
$$\frac{1}{|\zeta_n^{noi}|}\sum_{(x_j,\hat{y}j)\in\zeta_n^{noi}} r_j\left(\frac{\boldsymbol{\nabla\omega}M\left(x_j,y_j;\boldsymbol{\omega}\right)}{M\left(x_j,y_j;\boldsymbol{\omega}\right)}-\frac{\boldsymbol{\nabla_\omega}M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}{M\left(x_j,\hat{y}_j;\boldsymbol{\omega}\right)}\right)\Bigg]$$
$$\leqslant\frac{2e\left(\phi_{max}-\phi_{min}\right)}{|\zeta_n^{noi}|}+\frac{2e^2\left(\phi_{max}-\phi_{min}\right)\left(|\zeta_n^{noi}|^2-|\zeta_n^{noi}|\right)}{|\zeta_n^{noi}|^2}$$

(B-11)

将公式 (B-10) 和 (B-11) 代入 (B-9)，可以得到：

$$\mathbb{E}_r\mathbb{E}_{\zeta_n\sim\mathcal{D}_n}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)\right\|^2\right]$$
$$\leqslant\frac{4e\left(\phi_{max}-\phi_{min}\right)}{|\zeta_n^{noi}|}+\frac{4e^2\left(\phi_{max}-\phi_{min}\right)\left(|\zeta_n^{noi}|^2-|\zeta_n^{noi}|\right)}{|\zeta_n^{noi}|^2}$$

(B-12)

由此完成证明。若对任意 $\left(x_j,y_j+\epsilon_j\right)\in\mathcal{D}_n$ 都有 $\epsilon_j=0$，该分析依然成立。 ■