# 硕士学位论文

# 面向异构数据与资源受限场景的分割-联邦学习协同优化研究

# RESEARCH ON COLLABORATIVE OPTIMIZATION OF SPLIT FEDERATED LEARNING FOR HETEROGENEOUS DATA AND RESOURCE-CONSTRAINED SCENARIOS

研　　究　　生：田耕
指　导　教　师：唐茗副教授

南方科技大学

二〇二五年六月

国内图书分类号：XXxxx.x　　学校代码：14325
国际图书分类号：xx-x　　密级：公开

工学硕士学位论文

# 面向异构数据与资源受限场景的分割-联邦学习协同优化研究

学 位 申 请 人：田耕
指 导 教 师：唐茗副教授
学 科 名 称：电子科学与技术
答 辩 日 期：2020 年 12 月
培 养 单 位：计算机科学与工程系
学位授予单位：南方科技大学

Classified Index: XXxxx.x
U.D.C: xx-x

Thesis for the degree of Master of Engineering

# RESEARCH ON COLLABORATIVE OPTIMIZATION OF SPLIT FEDERATED LEARNING FOR HETEROGENEOUS DATA AND RESOURCE-CONSTRAINED SCENARIOS


| | |
|---|---|
| **Candidate:** | Tian Geng |
| **Supervisor:** | Assistant Prof. Alice Bob |
| **Discipline:** | Computer Science and Technology |
| **Date of Defence:** | December, 2020 |
| **Affiliation:** | School of System Design and Intelligent Manufacturing |
| **Degree-Conferring-Institution:** | Southern University of Science and Technology |

# 目 录

第 1 章 绪论 ..... 1
1.1 课题的研究背景与意义 ..... 1
1.2 国内外研究现状及分析 ..... 2
1.2.1 分布式学习方法在异构数据下的收敛性分析 ..... 2
1.2.2 轻量化客户端训练方案：无反向传播训练在分割-联邦学习中的应用 . 3
第 2 章 文献调研 ..... 4
2.1 分割-联邦学习框架下的收敛性分析 ..... 4
2.2 应对异构数据的分割-联邦学习算法 ..... 4
2.3 低开销的训练方法：无反向传播训练 ..... 5
第 3 章 异构数据对分割-联邦学习的影响以及优化方案 ..... 6
3.1 系统模型和问题背景 ..... 6
3.2 分割-联邦学习训练过程 ..... 7
3.3 分割-联邦学习的收敛性分析 ..... 8
3.3.1 均方误差损失函数 ..... 8
3.3.2 交叉熵损失函数 ..... 11
3.4 基于分割-联邦学习的鲁棒性算法 ..... 13
3.4.1 算法设计 ..... 13
3.4.2 树莓派测试平台的实现 ..... 16
3.5 实验部分 ..... 17
3.5.1 分割-联邦学习收敛性的实验验证 ..... 17
3.5.2 分割-联邦学习鲁棒性算法的实验验证 ..... 19
3.5.3 SFL-DCT 的结果 ..... 20
第 4 章 分割-联邦学习中轻量化客户端训练方案 ..... 22
4.1 无反向传播训练的实现 ..... 22
4.2 无反向传播训练对分割-联邦学习的性能提升 ..... 23
4.3 实验结果 ..... 24
4.4 未来研究计划 ..... 24
第 5 章 结论与展望 ..... 26
参考文献 ..... 27

附录 A ……30

# 第 1 章　绪论

## 1.1　课题的研究背景与意义

随着人工智能与移动互联网技术的迅猛发展，分布式学习已演变为一种关键范式：它能在严格保障隐私安全的同时，充分释放海量私有数据的潜在价值。在这一领域中，联邦学习（Federated Learning, FL）采用一种协同训练范式：客户端仅利用本地数据更新模型，服务器则负责周期性聚合各客户端的模型参数以生成全局模型。这种“共享模型参数而非原始数据”的机制，有效规避了数据隐私泄露风险。然而，传统联邦学习要求客户端在每轮训练中完整加载并更新上一轮的全局模型。面对日益庞大的深度学习模型，这一机制对客户端的计算算力与内存资源提出了严峻挑战，致使该方案在资源受限设备上的部署效率低下，甚至难以落地。

为突破这一瓶颈，分割联邦学习（Split Federated Learning, SFL）应运而生。SFL 借鉴了分割学习（Split Learning, SL）的模型切分理念，将全局模型划分为客户端模型与服务器端模型。在训练过程中，客户端仅需承担客户端模型的训练任务，而服务器端模型则由服务器负责训练。这种协作机制不仅有效继承了联邦学习的隐私保护特性，确保客户端数据特征仅对本地可见，还显著降低了客户端的计算和内存开销，为在资源受限环境下部署高参数量模型提供了可能。然而，尽管 SFL 理论上兼具隐私保护与计算效率优势，其在实际落地中仍面临数据异构性与系统资源受限的双重挑战，严重制约了其性能表现与推广应用。

首先，在数据层面，SFL 的性能表现高度依赖于客户端数据集的质量，然而现实场景中的数据往往呈现出显著的异构性。一方面，客户端之间的数据通常呈现非独立同分布（Non-IID）特性，这种分布差异性导致分布式训练过程难以逼近全局最优。另一方面，在数据收集与处理阶段，受限于人为标注失误、设备故障或传感器失效等因素，标签噪声（Label Noise）的产生往往难以避免，即出现样本标签与真实值不一致的现象。在分布式学习范式中，标签噪声会显著降低模型的收敛速度并削弱最终准确率。在 SFL 架构下，Non-IID 数据与标签噪声的耦合存在会进一步加剧训练的不稳定性。然而，目前针对 SFL 在复杂异构数据场景（即 Non-IID 与标签噪声共存）下的收敛性理论分析与算法优化研究仍相对匮乏。

其次，在系统资源层面，尽管 SFL 通过模型切分减轻了客户端的负担，但其训练过程仍受限于标准的反向传播（Backpropagation, BP）算法，导致了不可忽视的资源开销。具体而言，标准 BP 算法要求客户端不仅要在前向传播阶段计算并缓

存激活值（Activations），还需在反向传播阶段执行复杂的梯度（Gradients）计算。这两个过程不仅均涉及复杂的矩阵运算，造成了高昂的计算成本，其中间结果的存储需求也带来了显著的内存占用。此外，SFL 架构要求客户端与服务器针对每个小批量（Mini-batch）数据交换激活值与梯度，引入了显著的通信开销。对于计算能力有限、内存容量不足且网络带宽受限的边缘设备而言，现有的 SFL 训练机制依然显得沉重，亟需设计更高效的算法以突破计算、内存和通信资源的瓶颈。

综上所述，尽管 SFL 为隐私保护与资源受限场景下的分布式训练提供了创新路径，但其在异构数据环境下的收敛震荡与性能退化问题，以及在极端资源约束下的执行效率瓶颈，仍是亟待突破的关键科学问题。为此，本文立足于数据与系统双重维度，聚焦于 SFL 在异构数据环境下的收敛性分析与算法设计，以及资源受限场景下的轻量化训练机制，开展深入研究，旨在推动 SFL 在复杂现实场景中的高效、稳健应用。

## 1.2　国内外研究现状及分析

### 1.2.1　分布式学习方法的收敛性分析

There are many convergence results on FL. Most studies focus on data heterogeneity, e.g.,[1-5]. Some studies look at partial participation, e.g.,[? ? ? ]. There are also convergence results on Mini-Batch SGD, e.g.,[? ? ? ], where[? ] argued that the key difference between FL and Mini-Batch SGD is the communication frequency.

To our best knowledge, there is only one recent study[7] discussing the convergence of SL. The major difference to SL analysis lies in the sequential training manner across clients, while SFL clients perform parallel training.

#### 1.2.1.1　分割-联邦学习的收敛性分析

在分割-联邦学习框架下，模型被纵向划分并分别部署于客户端与服务器端，客户端仅负责浅层网络的计算，而深层网络由服务器统一维护与更新。这种架构虽降低了客户端的计算负担，但也引入了新的挑战，尤其是在面对非独立同分布（Non-IID）数据和标签噪声时，其收敛行为尚不明确。

本研究系统地分析了分割-联邦学习在均方误差（MSE）和交叉熵损失函数下的收敛特性。通过建立理论框架，推导了在存在标签噪声的情况下，客户端本地随机梯度的方差上界及其与期望梯度之间的偏差。在此基础上，进一步探讨了不同数据分布、模型拆分点、本地训练轮次等因素对全局模型收敛速度和最终性能的影响。实验验证表明，在合理配置训练参数的前提下，分割-联邦学习可以在标

签噪声和非独立同分布数据下稳定收敛，并保持较高的模型精度。

该部分的研究为后续鲁棒性算法的设计提供了理论支撑，也为分割-联邦学习在资源受限设备上的应用奠定了基础。

#### 1.2.1.2　对标签噪声和非独立同分布数据具有鲁棒性的分割-联邦学习算法

由于实际应用场景中数据往往具有异构性和噪声特征，如何提升分割-联邦学习对此类数据的鲁棒性成为关键问题。为此，本研究提出了 SFL-DCT 算法，旨在有效识别并修正标签噪声，同时缓解非独立同分布数据带来的负面影响。

SFL-DCT 分为三个阶段：第一阶段通过局部迭代训练提取每个客户端的数据特征，并基于 LID（Local Intrinsic Dimensionality）或 LE（Label Entropy）指标检测可能含有噪声标签的客户端；第二阶段利用干净客户端集合训练一个鲁棒模型，并用于识别噪声样本并进行标签修正；第三阶段则在修正后的数据集上进行标准的分割-联邦学习训练。整个过程结合高斯混合模型（GMM）分类技术，实现了对噪声客户端和噪声样本的自动识别与处理。

实验结果表明，SFL-DCT 在 CIFAR-10、CIFAR-100 和 Fashion-MNIST 等多个数据集上均表现出良好的鲁棒性。即使在高达 60% 的标签噪声率下，SFL-DCT 仍能维持较高的测试准确率，并优于传统联邦学习中的噪声鲁棒算法（如 FedCorr 和 FedNoRo）。此外，在 Non-IID 场景下，SFL-DCT 显著提升了模型的泛化能力，证明了其在异构环境中的有效性。

### 1.2.2　轻量化客户端训练方案：无反向传播训练在分割-联邦学习中的应用

为了进一步降低客户端的计算和内存开销，本研究首次将无反向传播训练机制引入分割-联邦学习框架中。传统的分割-联邦学习客户端需要执行前向传播和部分反向传播操作，这在资源受限设备上仍具有一定负担。为此，我们探索了多种无需依赖完整梯度反传的训练方法，如直接反馈对齐（Direct Feedback Alignment）、固定反馈权重等策略，并将其适配到分割-联邦学习的训练流程中。

具体而言，客户端侧采用无反向传播机制完成局部模型更新，仅需前向计算与少量反馈信号即可调整参数。这种设计显著减少了内存占用和计算复杂度，同时降低了通信成本。实验结果显示，相较于基于标准 SGD 的分割-联邦学习方法，引入无反向传播机制后，客户端的训练时间平均减少约 30%，且在多个视觉任务上的模型精度下降幅度控制在 2% 以内，展现了良好的性能与效率平衡。

该部分工作不仅拓展了分割-联邦学习的适用场景，还为边缘设备上的低功耗训练提供了新思路，具有较强的工程实用价值。

# 第 2 章　文献调研

## 2.1　分割-联邦学习框架下的收敛性分析

目前，针对联邦学习的收敛性分析已有大量研究成果[1-6]。Xiang Li 等人证明了非独立同分布数据下联邦学习在光滑和强凸问题中的收敛时间复杂度[6]。Sai Praneeth Karimireddy 等人证明了非独立同分布数据会在联邦学习中引起客户端漂移（Client-Drift）从而导致模型收敛速度慢和收敛过程不稳定[4]。然而，关于分割-联邦学习框架下的收敛性研究却相对匮乏，据我们所知，仅有一篇文献[7] 对该方向进行了初步探讨。现有工作尚未建立完整的收敛性分析框架，特别是在面对标签噪声和非独立同分布数据等实际场景时，缺乏系统且理论严谨的分析。

## 2.2　应对异构数据的分割-联邦学习算法

目前还没有研究提出过针对标签噪声和非独立同分布数据都具有鲁棒性的分割-联邦学习算法。目前分割-联邦学习中标签噪声的研究还较为有限，更多研究集中在非独立同分布数据上。Thapa 等人在文献[8] 中提出了分割-联邦学习算法，并探讨了其在非独立同分布数据上的鲁棒性。

联邦学习中已有很多分别应对标签噪声和非独立同分布数据的鲁棒性算法的研究。文献[9-16]专注于标签噪声对联邦学习的影响。Ke 等人在文献[9] 中从理论上分析了标签噪声对联邦学习中模型泛化能力的影响。Xu 等人在文献[11] 中提出了一种通用的联邦学习框架，通过多阶段过程检测和纠正噪声标签来应对标签噪声问题。Ji 等人在文献[14] 中探索结合全局模型与个性化模型的交替更新策略，以有效识别并过滤异构性的标签噪声。Feddiv[16] 使用了一种全局噪声过滤器，利用来自所有客户端的信息有效识别并剔除噪声标签，从而提高训练稳定性。FedNoRo[10] 利用知识蒸馏技术识别噪声客户端。Lycklama 等人在文献[12] 中通过对客户端更新施加约束（如范数限制）来增强联邦学习的鲁棒性，并有效缓解标签噪声带来的影响。FedLNL[15] 则通过交替更新本地噪声转换矩阵和分类器，并结合贝叶斯推理和本地多样性乘积正则化方法，提升了在标签噪声环境下的模型鲁棒性和准确性。还有一些工作通过修改聚合函数构建了对非独立同分布数据具有鲁棒性的联邦学习算法。Tian Li 在 FedAvg 的基础上引入了一个正则化项，提出了 FedProx[17]。FedProx 通过限制本地模型偏离全局模型的程度，帮助应对非独立同分布数据。Sashank J. Reddi 等人提出了 FedAdam[18]，这是一种基于 Adam 优化器的联邦学习算法。其使

用自适应优化方法，对全局更新使用一阶和二阶动量信息，以加速收敛，对于带有非独立同分布数据的复杂任务有一定的提升效果。Di Wu 等人提出了 FedAdapt[19]，它会动态调整聚合策略以适应不同客户端的模型更新步幅，以更好地处理高度非独立同分布的数据。

由于分割-联邦学习中模型被拆分且客户端与服务器之间存在训练耦合，因此这些针对联邦学习设计的鲁棒性算法算法不能直接应用于分割-联邦学习的场景。同时，这些算法也无法很好地同时处理非独立同分布数据和标签噪声。

通常在非独立同分布数据存在的情况下，分割-联邦算法有效处理标签噪声的能力会下降，其关键原因在于：在联邦学习中，服务器无法访问客户端的数据标签，因此无法了解每个客户端的数据分布情况。而我们通过引入分割-联邦学习来解决这一问题，因为在分割-联邦学习中，客户端数据的标签存储在服务器端，使得服务器能够获取所有客户端的数据分布信息。

## 2.3　低开销的训练方法：无反向传播训练

目前分割-联邦学习全部使用反向传播方法训练模型，这也是目前机器学习训练模型的主流方法。但反向传播计算梯度的过程需要大量的内存和计算资源，这对于参与分割-联邦学习的边缘设备来说是十分奢侈的。此外，分割-联邦学习中客户端与服务器需要额外进行一次通信来完成反向传播的过程，间接地增大了客户端的通信负载。已经有很多研究提出了不需要反向传播计算梯度的方法[20-25]，其中 Spall 等人[24]提出了同时扰动随机逼近（SPSA）方法，通过在参数上施加相反符号的扰动来近似梯度。Salimans 等人[25]提出了进化策略（ES）方法，通过向模型中注入随机噪声种群并沿最优方向优化参数。但这些方法都无法在较大尺寸模型上保持较高的准确率，并且这些无反向传播训练模型的方法与通用的机器学习框架不匹配，需要额外创建新的训练流程，无法与通用的数据处理、前向传播、损失计算等步骤相匹配。文献[26]提出了一种新型的无反向传播训练模型的方法，该方法通过向模型参数或激活值中注入噪声，观察损失的变化来估计梯度，这种方法极大地节约了设备的内存和算力，同时可以潜在地减少分割-联邦学习中客户端与服务器之间的通信负载。该方法的另一个优点是可以适配主流的机器学习框架，这为其与分割-联邦学习相结合铺平了道路。目前，还没有分割-联邦学习算法使用无反向传播训练方法，本研究将首次使用该方案来降低客户端训练过程中的内存、计算量和通信负载。

# 第 3 章　异构数据对分割-联邦学习的影响以及优化方案

## 3.1　系统模型和问题背景

我们考虑一个包含 $N$ 个客户端的集合，即 $\mathcal{N}=\{1,2,\cdots,N\}$，这些客户端通过分割-联邦学习协作训练一个全局神经网络模型。每个客户端 $n$ 都拥有一个数据集 $\mathcal{D}_n^{noi}$，由于在数据收集和处理过程中可能存在标签错误和人为误差，该数据集可能包含标签噪声[14,27]。$\mathcal{D}_n^{noi}$ 中的每一个数据样本 $i$ 被表示为 $(x_i,\tilde{y}_i)$，其中带有噪声的标签 $\tilde{y}_i$ 可能与真实标签 $y_i$ 不同, 并且不同用户的数据标签分布并非独立同分布。

为了方便起见，我们为每个客户端 $n$ 定义一个干净的数据集 $\mathcal{D}_n^{cle}$，它与 $\mathcal{D}_n^{noi}$ 相关联，但其中的标签噪声已被修正。$\mathcal{D}_n^{cle}$ 中的每个数据样本 $i$ 被表示为 $(x_i,y_i)$，其标签噪声已被去除。去除标签噪声的操作可以通过人工方式进行。令 $D_n=|\mathcal{D}_n^{noi}|=|\mathcal{D}_n^{cle}|$ 表示客户端 $n$ 数据集中数据样本的数量。

在一个分割-联邦学习系统中，我们使用 $\boldsymbol{\omega}$ 来表示全局模型。该全局模型被划分为两个部分：一个 $l_c$ 层的客户端侧模型，记作 $\boldsymbol{\omega}_{\mathrm{c}}$；一个 $l_s$ 层的服务器侧模型，记作 $\boldsymbol{\omega}_{\mathrm{s}}$。特别地，客户端侧模型 $\boldsymbol{\omega}_{\mathrm{c}}$ 和服务器侧模型 $\boldsymbol{\omega}_{\mathrm{s}}$ 共同构成完整的全局模型，即 $\boldsymbol{\omega}=(\boldsymbol{\omega}_{\mathrm{c}},\boldsymbol{\omega}_{\mathrm{s}})$。

在分割-联邦学习系统中有两个服务器（如图 3-1 所示）：

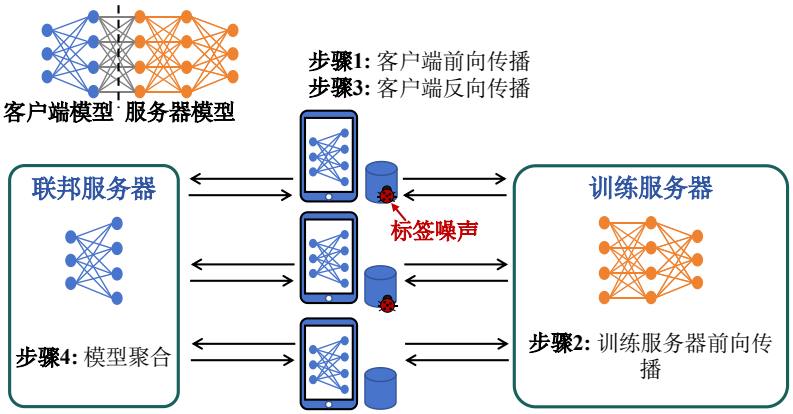


图 3-1　分割-联邦学习框架与异构数据。

- **联邦服务器**（Fed Server），负责协调各客户端以分布式方式训练客户端侧模型 $\boldsymbol{\omega}_{\mathrm{c}}$；

- **训练服务器**（Training Server），负责以集中式方式训练服务器侧模型 $\boldsymbol{\omega}_{\mathrm{s}}$。

分割-联邦学习中有两种典型的算法：SFL-V1 和 SFL-V2[8]。它们的区别在于

训练服务器如何更新服务器侧模型。本课题聚焦于 SFL-V2，原因如下：

(i)如文献[8] 所建议，SFL-V2 的性能通常优于 SFL-V1；

(ii)SFL-V2 的分析比 SFL-V1 更具挑战性。①

## 3.2　分割-联邦学习训练过程

分割-联邦学习的训练持续 $R$ 轮。在每一轮 $r$ 中，客户端 $n \in \mathcal{N}$ 从联邦服务器下载客户端侧模型 $\boldsymbol{\omega}_{\mathrm{c},n}^{r-1}$，该模型作为第 $r$ 轮中客户端 $n$ 的初始模型 $\boldsymbol{\omega}_{\mathrm{c},n}^{r}$。令 $\boldsymbol{\omega}_{\mathrm{s}}^{r}$ 表示第 $r$ 轮的服务器模型，其由上一轮的服务器模型初始化而来。在第 $r$ 轮中，客户端 $n$ 和服务器使用数据集 $\mathcal{D}_n^{\mathrm{oi}}$ 对模型进行 $E$ 轮（epoch）的训练。在每一轮中，客户端将其数据集划分为多个小批量（mini-batch），并依次用于对模型 $\boldsymbol{\omega}_{\mathrm{c},n}^{r}$ 和 $\boldsymbol{\omega}_{\mathrm{s}}^{r}$ 进行更新。第 $r$ 轮中针对一个小批量 $\zeta_n^{noi} \subset \mathcal{D}_n^{\mathrm{oi}}$ 的训练过程包含以下四个步骤：

**步骤 1：客户端前向传播**。客户端 $n$ 使用小批量 $\zeta_n^{noi}$ 在其本地客户端侧模型 $\boldsymbol{\omega}_{\mathrm{c},n}^{r}$ 上进行前向传播。

随后，每个客户端将其计算得到的中间激活值（即 $\boldsymbol{\omega}_{\mathrm{c},n}^{r}$ 前向传播的输出）以及数据标签发送给训练服务器。

**步骤 2：训练服务器前向传播**。训练服务器在接收到客户端的中间激活值后，在模型 $\boldsymbol{\omega}_{\mathrm{s}}^{r}$ 上执行前向传播以生成预测标签并计算损失函数。需要注意的是，服务器侧模型 $\boldsymbol{\omega}_{\mathrm{s}}^{r}$ 对某个客户端激活值的更新仅在其之前对其他更早到达的客户端激活值的更新完成后才开始。

**步骤 3：训练服务器反向传播**。训练服务器根据计算出的损失函数计算梯度，并据此更新模型 $\boldsymbol{\omega}_{\mathrm{s}}^{r}$。由于服务器侧模型 $\boldsymbol{\omega}_{\mathrm{s}}^{r}$ 仅包含完整模型中的 $l_s$ 层，训练服务器会将中间梯度发送回客户端 $n$，以便其更新客户端侧模型 $\boldsymbol{\omega}_{\mathrm{c},n}$。

**步骤 4：客户端反向传播**。客户端 $n$ 在接收到中间梯度后，继续完成反向传播过程，从而更新本地的客户端侧模型 $\boldsymbol{\omega}_{\mathrm{c},n}^{r}$。至此，一个小批量的训练过程完成。

**步骤 5：模型聚合**。在每一轮训练中，每个客户端 $n$ 需要与训练服务器进行 $E \times \left\lceil \frac{|\mathcal{D}_n|}{|\zeta_n|} \right\rceil$ 次交互，以确保客户端 $n$ 的数据被使用 $E$ 次。当所有客户端完成训练后，联邦服务器通过加权平均的方式计算全局客户端侧模型 $\boldsymbol{\omega}_{\mathrm{c}}^{r}$：

$$\boldsymbol{\omega}_{\mathrm{c}}^{r} = \sum_{n=1}^{N} \frac{|\mathcal{D}_n|}{\sum_{n'=1}^{N} |\mathcal{D}_{n'}|} \boldsymbol{\omega}_{\mathrm{c},n}^{r}. \tag{3-1}$$

注意，训练服务器维护着全局的服务器侧模型 $\boldsymbol{\omega}_{\mathrm{s}}^{r}$，无需对其进行聚合操作。当客户端和服务器完成 $R$ 轮训练后，最终的完整模型为 $\boldsymbol{\omega}^{R} = (\boldsymbol{\omega}_{\mathrm{c}}^{R}, \boldsymbol{\omega}_{\mathrm{s}}^{R})$。

① 我们的分析可以通过遵循现有的联邦学习收敛性分析文献（例如[4,28]）扩展到 SFL-V1。

## 3.3　分割-联邦学习的收敛性分析

本部分从理论上分析带标签噪声的非独立同分布数据集对分割-联邦学习收敛性的影响，其中关键挑战在于回答如何在收敛性分析中量化标签噪声这一问题。

如前所述，文献[9] 在联邦学习（FL）中量化了标签噪声，但其重点是模型的泛化能力，而非收敛性，因此其分析方法在此并不适用。同时，据我们所知，目前尚无研究在分割-联邦学习或联邦学习的收敛性分析中对标签噪声进行过量化。

为填补这一空白，我们提出首先量化标签噪声对随机梯度的值及其方差的影响，从而可以沿用传统的证明路径来推导出收敛速率。这种方法为将标签噪声纳入分割-联邦学习收敛性分析提供了分析框架，并可扩展至其他分割-联邦学习或联邦学习算法。

具体而言，令 $\zeta_n^{cle}$ 表示客户端 $n$ 的干净数据集 $\mathcal{D}_n^{cle}$ 中的一个小批量。设 $F_n(\boldsymbol{\omega};\zeta_n^{cle})$ 表示完整模型 $\boldsymbol{\omega}$ 在客户端 $n$ 的小批量 $\zeta_n^{cle}$ 上的损失函数。客户端 $n$ 的期望损失为

$$F_n^{cle}(\boldsymbol{\omega}) = \mathbb{E}_{\zeta_n^{cle}\sim\mathcal{D}_n^{cle}}\left[F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right)\right]. \tag{3-2}$$

分割-联邦学习的目标是学习一个模型 $\boldsymbol{\omega}^*$，使其最小化所有客户端上损失函数 $F_n(\boldsymbol{\omega})$ 的加权平均值[29]：

$$\boldsymbol{\omega}^* = \arg\min_{\boldsymbol{\omega}} f(\boldsymbol{\omega}) \triangleq \sum_{n=1}^{N} \frac{|\mathcal{D}_n|}{\sum_{n'=1}^{N}|\mathcal{D}_{n'}|} F_n^{cle}(\boldsymbol{\omega}). \tag{3-3}$$

需要注意的是，分割-联邦学习的训练过程是基于所有客户端 $n \in \mathcal{N}$ 的带噪声数据集 $\mathcal{D}_n^{noi}$ 进行的；而如式 (3-3) 所述，其优化目标仍然是使模型 $\boldsymbol{\omega}^R$ 拟合所有客户端的干净数据集 $\mathcal{D}_n^{cle}$。

接下来，我们将分别在标签噪声环境下，针对均方误差（MSE）损失函数与交叉熵（Cross-Entropy）损失函数对分割-联邦学习的收敛性进行分析。

### 3.3.1　均方误差损失函数

#### 3.3.1.1　标签噪声下的损失函数

在本节中，我们考虑使用均方误差（MSE）作为损失函数。均方误差可用于机器学习中的任务，例如回归。对于这些任务，由于标签通常是连续值，我们在标签 $y_i$ 上添加一个服从正态分布的随机噪声 $\epsilon_i$，即 $\epsilon_i \sim \mathbb{N}(\mu,\sigma^2)$，其中 $\mu$ 和 $\sigma^2$ 分别为噪声的均值和方差。这种噪声设置被现有研究广泛采用（例如[30]）。

同时，我们设置 $\mu = 0$ 以确保加入噪声后标签的平均值不变。则数据集 $\mathcal{D}_n^{noi}$ 中的样本 $i$ 表示为 $(x_i, \tilde{y}_i \triangleq y_i + \epsilon_i)$。令 $h(x_i;\boldsymbol{\omega})$ 表示使用模型 $\boldsymbol{\omega}$ 对特征 $x_i$ 的预测

标签值。模型 $\boldsymbol{\omega}$ 在一个小批量 $\zeta$ 上的 MSE 损失函数 $F_n(\boldsymbol{\omega};\zeta)$ 定义如下：

$$F_n(\boldsymbol{\omega};\zeta)=\frac{1}{|\zeta|}\sum_{(x_i,y_i)\in\zeta}\left(h(x_i;\boldsymbol{\omega})-y_i\right)^2. \tag{3-4}$$

因此，我们可以将含噪声数据集下的损失函数用干净数据集下的损失函数表示如下：

**引理 3.1 (带标签噪声的均方误差)**：考虑一个小批量 $\zeta_n^{noi}$ 及其对应的干净小批量 $\zeta_n^{cle}$，则有

$$F_n\left(\boldsymbol{\omega};\zeta_n^{noi}\right)=F_n\left(\boldsymbol{\omega};\zeta_n^{cle}\right)+\frac{1}{|\zeta_n^{noi}|}\sum_{(x_i,\tilde{y}_i)\in\zeta_n^{noi}}\left(\epsilon_i^2-2\left(h(x_i;\boldsymbol{\omega})-y_i\right)\epsilon_i\right). \tag{3-5}$$

#### 3.3.1.2　假设条件

如同许多已有工作（例如[28-29,31]），我们在收敛分析中对随机梯度和损失函数做出一些假设。令 $\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n)$ 表示 $F_n(\boldsymbol{\omega};\zeta_n)$ 在小批量 $\zeta_n$ 上的随机梯度，即 $\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n)\triangleq\nabla F_n(\boldsymbol{\omega};\zeta_n)$。令 $\nabla F_n^{cle}(\boldsymbol{\omega})$ 表示客户端 $n\in\mathcal{N}$ 的干净数据集上期望损失 $F_n^{cle}(\boldsymbol{\omega})$ 的梯度，定义见公式 (3-2)。令 $\nabla F_n^{noi}(\boldsymbol{\omega})$ 表示对应于噪声数据集的期望损失梯度。对于任意客户端 $n\in\mathcal{N}$，来自干净数据集 $\mathcal{D}_n^{cle}$ 的小批量上的随机梯度满足以下假设：

**假设 3.1 (均方误差下随机梯度的方差)**：对于任意客户端 $n\in\mathcal{N}$，$\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)$ 在干净小批量上的期望方差是有界的，即：

$$\mathbb{E}_{\zeta_n^{cle}\sim\mathcal{D}_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\nabla F_n^{cle}(\boldsymbol{\omega})\right\|^2\right]\leqslant\phi_n^2. \tag{3-6}$$

**假设 3.2 (均方误差下的随机梯度)**：对于任意客户端 $n\in\mathcal{N}$，$\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)$ 在 clean 数据集 $\mathcal{D}_n^{cle}$ 上的期望随机梯度是有界的，即：

$$\mathbb{E}_{\zeta_n^{cle}\sim\mathcal{D}_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)\right\|^2\right]\leqslant G_n^2. \tag{3-7}$$

**假设 3.3 (数据异构性)**：所有客户端 $n\in\mathcal{N}$ 的期望梯度 $\nabla F_n(\boldsymbol{\omega})$ 的方差是有界的，即：

$$\left\|\nabla F_n(\boldsymbol{\omega})-\textstyle\sum_{n\in\mathcal{N}}\nabla F_n(\boldsymbol{\omega})/N\right\|^2\leqslant\lambda^2. \tag{3-8}$$

这里，$\nabla F_n(\boldsymbol{\omega})$ 同时表示 $\nabla F_n^{cle}(\boldsymbol{\omega})$ 和 $\nabla F_n^{noi}(\boldsymbol{\omega})$。①

我们对损失函数作出如下假设：②

① 注意，非独立同分布（non-IID）和标签噪声可以建模为相互独立的事件，前者涉及客户端的数据分布，后者涉及标签如何被破坏。

② 虽然我们使用均方差作为损失函数，但损失函数相对于全局模型的性质依赖于分割-联邦学习中的模型结

**假设 3.4 ($S$-平滑性)**：对于任意模型 $\boldsymbol{\omega}_1, \boldsymbol{\omega}_2 \in \mathbb{R}^d$，损失函数是 $S$-平滑的，即：

$$F_n(\boldsymbol{\omega}_2) \leqslant F_n(\boldsymbol{\omega}_1) + \langle \boldsymbol{\nabla} F_n(\boldsymbol{\omega}_1), \boldsymbol{\omega}_2 - \boldsymbol{\omega}_1 \rangle + \frac{S}{2} \|\boldsymbol{\omega}_2 - \boldsymbol{\omega}_1\|^2.$$

#### 3.3.1.3　收敛性分析

我们首先分析在噪声数据集下随机梯度相关的界，然后对分割-联邦学习的收敛性进行界定。

**标签噪声存在时的随机梯度**：考虑到数据集中存在标签噪声，(3-6) 和 (3-7) 中定义的随机梯度 $\boldsymbol{g}_n(\cdot)$ 相关的界会增加。特别地，含噪声数据集上的随机梯度 $\boldsymbol{g}_n(\boldsymbol{\omega}, \zeta_n^{noi})$ 可表示为干净数据集上的随机梯度 $\boldsymbol{g}_n(\boldsymbol{\omega}, \zeta_n^{cle})$ 的表达式，如下所示：

$$\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right) = \boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{cle}\right) - \frac{1}{|\zeta_n^{noi}|} \sum_{(x_i, y_i + \epsilon_i) \in \zeta_n^{noi}} 2\epsilon_i \boldsymbol{\nabla} h\left(x_i; \boldsymbol{\omega}\right). \quad (3\text{-}9)$$

因此，我们可以分别界定含噪声数据集下的随机梯度的方差和值。

**命题 3.1 (均方差损失下含标签噪声的随机梯度的方差)**：在假设 3.1 下，任意客户端 $n \in \mathcal{N}$ 在噪声小批量上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)$ 的期望方差是有界的：

$$\mathbb{E}_{\zeta_n^{noi} \sim \mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right) - \boldsymbol{\nabla} F_n^{noi}\left(\boldsymbol{\omega}\right)\right\|^2\right] \leqslant \phi_n^2 + H_1^2, \quad (3\text{-}10)$$

其中 $H_1^2$ 定义为：

$$H_1^2 = \frac{8\sigma^2}{|\mathcal{D}_n^{noi}|^2} \sum_{(x_i, y_i + \epsilon_i) \in \mathcal{D}_n^{noi}} \left(\boldsymbol{\nabla}_\omega h\left(x_i; \boldsymbol{\omega}\right)\right)^2 + \frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|} \sum_{(x_i, y_i + \epsilon_i) \in \mathcal{D}_n^{noi}} \left(\boldsymbol{\nabla}_\omega h\left(x_i; \boldsymbol{\omega}\right)\right)^2 \quad (3\text{-}11)$$

**命题 3.2 (均方差损失下含标签噪声的随机梯度的平方的期望)**：在假设 3.2 下，任意客户端 $n \in \mathcal{N}$ 在噪声数据集 $\mathcal{D}_n^{noi}$ 上的 $\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)$ 是有界的，即：

$$\mathbb{E}_{\zeta_n^{noi} \sim \mathcal{D}_n^{noi}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega}, \zeta_n^{noi}\right)\right\|^2\right] \leqslant G_n^2 + H_2^2, \quad (3\text{-}12)$$

其中 $H_2^2$ 定义为：

$$H_2^2 = \sum_{\zeta_n^{noi} \subset \mathcal{D}_n^{noi}} \frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|} \sum_{\left(x_j, y_j + \epsilon_j\right) \in \zeta_n^{noi}} \left(\boldsymbol{\nabla}_\omega h\left(x_j; \boldsymbol{\omega}\right)\right)^2 \quad (3\text{-}13)$$

命题 3.1–3.2 的证明分别见附录 A.1–A.2。

为了处理分割-联邦学习中的模型拆分操作，根据[29]，我们提出以下引理，将

构和小批量中的数据样本。因此，如同现有工作（例如[28-29,31]），我们需要对损失函数施加假设以便进行分析。

期望损失的界分解为两个项，分别对应服务器端和客户端模型。令 $\boldsymbol{\omega}^* \triangleq (\boldsymbol{\omega}_{\mathrm{c}}^*; \boldsymbol{\omega}_{\mathrm{s}}^*)$ 表示使 $f(\boldsymbol{\omega})$ 最小化的最优全局模型，定义见 (3-3)。令 $\boldsymbol{\omega}^R \triangleq (\boldsymbol{\omega}_{\mathrm{c}}^R; \boldsymbol{\omega}_{\mathrm{s}}^R)$ 表示经过 $R$ 轮训练后获得的全局模型。

**引理 3.2 (收敛性分析中的模型拆分[29])**：通过分割-联邦学习训练得到的模型与最优模型之间的性能差距上界如下：

$$\mathbb{E}\left[f(\boldsymbol{\omega}^R)\right] - f(\boldsymbol{\omega}^*) \leqslant \frac{S}{2}\left(\mathbb{E}||\boldsymbol{\omega}_{\mathrm{s}}^R - \boldsymbol{\omega}_{\mathrm{s}}^*||^2 + \mathbb{E}||\boldsymbol{\omega}_{\mathrm{c}}^R - \boldsymbol{\omega}_{\mathrm{c}}^*||^2\right). \tag{3-14}$$

然后，我们可以得出关于含噪声数据集的分割-联邦学习收敛性的主要结果。我们沿用了[29] 的证明路径，由于篇幅限制，省略了详细证明。令 $b$ 表示小批量大小，我们定义以下几个记号：

$$\kappa = \left\lceil \frac{D_n}{b} \right\rceil \times E, \quad a_n = \frac{D_n}{\sum_{n'=1}^{N} D_{n'}}, \quad \forall n.$$

现在给出收敛性结果。

**定理 3.1 (均方差损失下的收敛性)**：在假设 3.1–3.4 以及均方差损失函数 (3-4) 下，若 $\eta^r \leqslant \min\left\{1/(16S\kappa), 1/(8SN\kappa\sum_{n=1}^{N} a_n^2)\right\}$，则：

$$\begin{aligned}\frac{1}{R}\sum_{r=0}^{R-1}\eta^r\mathbb{E}\left[\|\boldsymbol{\nabla}_{\boldsymbol{\omega}} f(\boldsymbol{\omega}^r)\|^2\right] &\leqslant \frac{4}{R\kappa}\left(f\left(\boldsymbol{\omega}^0\right) - f(\omega^*)\right) \\ &+ O\left(\frac{NS\kappa}{R}\sum_{n=1}^{N} a_n^2\left(\phi_n^2 + \lambda^2 + H_1^2 + H_2^2\right)\sum_{R=0}^{R-1}(\eta^r)^2\right).\end{aligned} \tag{3-15}$$

收敛界随着客户端噪声的方差 $\sigma^2$ 增大而增大。这从理论上刻画了在均方差损失下标签噪声如何减缓分割-联邦学习的收敛速度。

### 3.3.2　交叉熵损失函数

在本节中，我们将收敛性分析扩展至分类任务中常用的交叉熵（cross-entropy）损失函数。对于这些任务，标签通常是离散的，因此我们考虑标签的随机翻转，而不是像均方误差（MSE）情况下那样添加随机噪声。具体来说，设 $\mathcal{K}$ 表示标签类别集合。

令 $\delta$ 表示噪声率，即标签 $y_i$ 被替换成不同标签 $\tilde{y}_i$ 的概率。回顾一下，$h(x_i; \boldsymbol{\omega})$ 是模型 $\boldsymbol{\omega}$ 下特征 $x_i$ 的输出。对于交叉熵损失，$h(x_i; \boldsymbol{\omega})$ 是一个包含 $K \triangleq |\mathcal{K}|$ 个项的向量，在深度学习中称为 logits。令 $M(x_i, y_i; \boldsymbol{\omega})$ 表示对模型输出的 logits 应用 softmax 函数后，给定输入 $x_i$ 和模型参数 $\boldsymbol{\omega}$ 时模型预测标签 $y_i$ 的概率，其定义如

下：

$$M(x_i, y_i; \boldsymbol{\omega}) = \frac{e^{[h(x_i;\boldsymbol{\omega})]_{y_i}}}{\sum_{y\in\mathcal{K}} e^{[h(x_i;\boldsymbol{\omega})]_y}}, \tag{3-16}$$

其中 $[h(x_i;\boldsymbol{\omega})]_{y_i}$ 表示 $h(x_i;\boldsymbol{\omega})$ 中与 $y_i$ 对应的项。于是，小批量 $\zeta$ 上的交叉熵损失 $F_n(\boldsymbol{\omega};\zeta)$ 定义如下：

$$F_n(\boldsymbol{\omega};\zeta) = \frac{1}{|\zeta|}\sum_{(x_i,y_i)\in\zeta} -\log\left(M(x_i, y_i; \boldsymbol{\omega})\right), \tag{3-17}$$

其中 $F_n(\boldsymbol{\omega};\zeta)$ 仍满足假设 3.4。

令 $r_i$ 表示数据样本 $(x_i, y_i)$ 是否被翻转的指示变量，即 $r_i \sim Bernoulli(\delta)$。将 (3-17) 中定义的交叉熵损失代入梯度 $\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n) \triangleq \nabla F_n(\boldsymbol{\omega};\zeta_n)$，我们可以得到含噪小批量 $\zeta_n^{noi}$ 上的梯度与其对应的干净小批量 $\zeta_n^{cle}$ 上的梯度之间的关系：

$$\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right) = \boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right) + \frac{1}{|\zeta_n^{noi}|}\sum_{(x_i,\tilde{y}_i)\in\zeta_n^{noi}} r_i \times\left(\frac{\nabla_{\boldsymbol{\omega}} M(x_i, y_i; \boldsymbol{\omega})}{M(x_i, y_i; \boldsymbol{\omega})} - \frac{\nabla_{\boldsymbol{\omega}} M(x_i, \tilde{y}_i; \boldsymbol{\omega})}{M(x_i, \tilde{y}_i; \boldsymbol{\omega})}\right). \tag{3-18}$$

为了进行收敛性分析，我们假设 $M(x_i, y_i; \boldsymbol{\omega})$ 的梯度与其本身的比值始终有界。**假设 3.5 (与 $M(\cdot)$ 相关的界)**：设 $(x_i, \tilde{y}_i)$ 和 $\left(x_j, \tilde{y}_j\right)$ 表示来自 $\mathcal{D}_n^{noi}$ 或 $\mathcal{D}_n^{cle}$ 的任意一对数据样本。假设以下内积始终有上下界：

$$\psi_{min} \leqslant \left\langle \frac{\nabla M(x_i, \tilde{y}_i; \boldsymbol{\omega})}{M(x_i, \tilde{y}_i; \boldsymbol{\omega})}, \frac{\nabla M(x_j, \tilde{y}_j; \boldsymbol{\omega})}{M(x_j, \tilde{y}_j; \boldsymbol{\omega})} \right\rangle \leqslant \psi_{max}, \tag{3-19}$$

由于模型 $\boldsymbol{\omega}$ 的输出和 softmax 函数是光滑的，且每个样本的预测概率是有界的，因此该内积的上下界存在。根据假设 3.5，我们可以放松假设 3.1 和 3.2，并确定干净数据集上随机梯度的方差和期望平方梯度的上界形式如下：

$$\mathbb{E}_{\zeta_n^{cle}\sim\mathcal{D}_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right) - \nabla F_n^{cle}(\boldsymbol{\omega})\right\|^2\right] \leqslant \phi_n^2 \triangleq 2\psi_{max} - 2\psi_{min}, \tag{3-20}$$

$$\mathbb{E}_{\zeta_n^{cle}\sim\mathcal{D}_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)\right\|^2\right] \leqslant G_n^2 \triangleq \psi_{max}. \tag{3-21}$$

为了分析收敛性，类似于第 3.3.1 节中对均方误差损失的处理，我们可以首先通过将 $\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)$ 代入表达式 $\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}[\|\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n^{noi}) - \nabla F_n^{noi}(\boldsymbol{\omega})\|^2]$ 和 $\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}[\|\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n^{noi})\|^2]$ 并结合期望变换来求出含噪情况下的随机梯度方差和期望平方梯度的上界。然后根据引理 3.2，我们可以得到在交叉熵损失下分割-联邦学习的收敛性结果如下。

**定理 3.2 (交叉熵损失下的收敛性)**：在假设 3.3–3.5 以及 (3-16) 中定义的交叉熵损失

函数下，若 $\eta^r \leqslant \min\left\{1/(16S\kappa), 1/(8SN\kappa\sum_{n=1}^{N} a_n^2)\right\}$，则 $\frac{1}{R}\sum_{r=0}^{R-1}\eta^r\mathbb{E}[\|\boldsymbol{\nabla}_{\boldsymbol{\omega}} f(\boldsymbol{\omega}^r)\|^2]$ 的上界如定理 3.1 所述成立，仅更改 $H_1^2$ 和 $H_2^2$ 为如下形式：

$$H_1^2 = 4\delta\left(\frac{\Delta}{Z} + \frac{3\Delta}{D}\right) - 4\delta^2\left(4 + \frac{\Delta}{Z} + \frac{3\Delta}{D}\right), \tag{3-22}$$

$$H_2^2 = 4\delta\frac{\Delta}{Z} + 4\delta^2\left(1 - \frac{\Delta}{Z}\right), \tag{3-23}$$

其中 $\Delta \triangleq \psi_{max} - \psi_{min}$，$Z \triangleq |\zeta_n^{noi}| = |\zeta_n^{cle}|$，且 $D \triangleq |\mathcal{D}_n^{noi}| = |\mathcal{D}_n^{cle}|$ 对于所有 $n \in \mathcal{N}$ 成立。

收敛速率的上界随着客户端噪声方差 $O(\delta^2)$ 的增加而增大。这从理论上刻画了在交叉熵损失下，标签噪声如何减缓分割-联邦学习的收敛速度。

## 3.4　基于分割-联邦学习的鲁棒性算法

为了解决 SFL 中的标签噪声问题，我们在 SFL-V2 的基础上提出了 SFL-DCT 算法。SFL-DCT 受文献[11] 中一种应对联邦学习（FL）中标签噪声算法 FedCorr 的启发。与已有工作不同的是，我们联合处理了分割-联邦学习中的非独立同分布（non-IID）数据和标签噪声问题，通过利用分割-联邦学习中服务器端可用的标签信息，并结合基于熵的思想来进行噪声检测。

为了评估 SFL-DCT 在实际场景中的性能，我们搭建了一个实验测试平台来实现该算法，这需要精心设计（例如并行传输、高效的内存与 CPU 使用），以减少训练延迟。接下来，我们将首先介绍算法的具体细节, 然后介绍实验测试平台的设计。

### 3.4.1　算法设计

SFL-DCT 的核心思想是先检测再修正标签噪声。该算法包含三个阶段：

**第一阶段：**使用本地内在维度（LID）检测独立同分布数据中的含噪客户端，使用标签熵（LE）检测非独立同分布数据中的含噪客户端。**第二阶段：**利用来自干净客户端的数据训练全局模型，然后检测并修正来自含噪客户端的错误标签。**第三阶段：**在修正后的数据样本上进行传统的 SFL 训练。

为便于表述，我们使用 $\boldsymbol{\omega}$ 表示需要训练的全局模型，并省略训练轮次的索引。需要注意的是，每个阶段（特别是第二或第三阶段）所使用的初始全局模型是前一阶段训练完成的模型。我们用 $\mathcal{D}_n$ 表示客户端 $n$ 的原始数据集。在第二阶段中，部分含噪标签会被修正，从而得到客户端 $n$ 的更新数据集，记作 $\mathcal{D}_n'$。

SFL-DCT 算法的伪代码如算法 3-1 所示，图 3-2 展示了 SFL-DCT 的整体流程。

第一阶段的目标是检测存在标签噪声的客户端。在分割-联邦学习中，客户端

算法 3-1　SFL-DCT 算法

初始化全局模型 $\boldsymbol{\omega} = (\boldsymbol{\omega}_{\mathrm{c}}, \boldsymbol{\omega}_{\mathrm{s}})$ 和本地模型 $(\boldsymbol{\omega}_n, n \in \mathcal{N})$，其中 $\boldsymbol{\omega}_n = (\boldsymbol{\omega}_{\mathrm{c},n}, \boldsymbol{\omega}_{\mathrm{s}})$；
// 第一阶段：噪声检测
根据 (3-24) 计算每个客户端 $n$ 的系数 $\gamma_n$；
**if** $\max_{n\in\mathcal{N}}\{\gamma_n\} > \tau$ **then**
　根据 (3-27) 计算每个客户端 $n$ 的 $\mathrm{LE}_n$；
　基于所有 $n \in \mathcal{N}$ 的 $\mathrm{LE}_n$，使用高斯混合模型（GMM）识别出干净客户端集合 $\mathcal{N}_{cle}$ 与含噪客户端集合 $\mathcal{N}_{noi}$；
**else**
　$\boldsymbol{\omega} \leftarrow$ 所有客户端使用其数据集 $\mathcal{D}_n$，按照第 3.2 节中步骤 1–4 进行 $R_0$ 轮 SFL 训练；
　根据 (3-26) 计算每个客户端 $n$ 的 $\mathrm{LID}_n$；
　基于所有 $n \in \mathcal{N}$ 的 $\mathrm{LID}_n$，使用 GMM 识别出干净客户端集合 $\mathcal{N}_{cle}$ 与含噪客户端集合 $\mathcal{N}_{noi}$；
**end if**
$\boldsymbol{\omega} \leftarrow$ 所有客户端 $n \in \mathcal{N}$ 使用其数据集 $\mathcal{D}_n$，按照第 3.2 节中步骤 1–4 继续进行 SFL 训练，直到完成 $R_1$ 轮；
// 第二阶段：噪声修正
$\boldsymbol{\omega} \leftarrow$ 干净客户端集合 $\mathcal{N}_{cle}$ 使用其数据集 $\mathcal{D}_n$，按照第 3.2 节中步骤 1–4 进行 $R_2$ 轮 SFL 训练；
$loss_{n,i} \leftarrow$ 每个客户端 $n$ 中每条数据 $i$ 的测试损失；
**for** 每个客户端 $n \in \mathcal{N}_{noi}$ **do**
　$\hat{\mathcal{D}}_n^{noi} \leftarrow$ 对所有 $i$ 上的 $loss_{n,i}$ 使用 GMM 进行分类，识别出含噪数据集合；
　**for** 每个 $(x_i, \tilde{y}_i) \in \hat{\mathcal{D}}_n^{noi}$ **do**
　　客户端 $n$ 计算 $h(x_i; \boldsymbol{\omega}_{\mathrm{c},n})$ 并将 smashed data 发送给训练服务器；
　　训练服务器计算 $h(x_i; \boldsymbol{\omega}_n)$，并基于输出 $h(x_i; \boldsymbol{\omega}_n)$ 修正标签 $\tilde{y}_i$；
　**end for**
**end for**
// 第三阶段：*SFL* 训练
$\boldsymbol{\omega} \leftarrow$ 所有客户端 $n \in \mathcal{N}$ 使用更新后的数据集 $\mathcal{D}_n'$（已完成标签噪声修正）按照第 3.2 节中步骤 1–4 进行 $R_3$ 轮 SFL 训练；
**return** $\boldsymbol{\omega}$.

会在训练过程中将标签发送给服务器[8,32]。服务器为每个客户端 $n$ 计算一个系数 $\gamma_n$，用以反映该客户端数据集的非独立同分布（non-IID）程度。

为了计算 $\gamma_n$，服务器按升序排列客户端 $n$ 的标签频率。设 $(y_{(1)}^n, y_{(2)}^n, \cdots, y_{(|\mathcal{K}|)}^n)$ 表示排序后的标签。

然后，$\gamma_n$ 通过计算前 $\lfloor K/2 \rfloor$ 个标签所占数据样本的比例来确定：

$$\gamma_n = \frac{\sum_{i=1}^{\lfloor K/2 \rfloor} \mathrm{count}(y_{(i)}^n)}{|\mathcal{D}_n|}, \tag{3-24}$$

其中 $\mathrm{count}(y_{(i)}^n)$ 表示具有标签 $y_{(i)}^n$ 的数据样本数量。

根据所有 $n \in \mathcal{N}$ 的 $\gamma_n$ 值，我们选择合适的方法来检测含噪客户端。有两种候选方法：基于 LID 的检测和基于 LE 的检测。前者来源于文献[11]，更适合 IID 数据

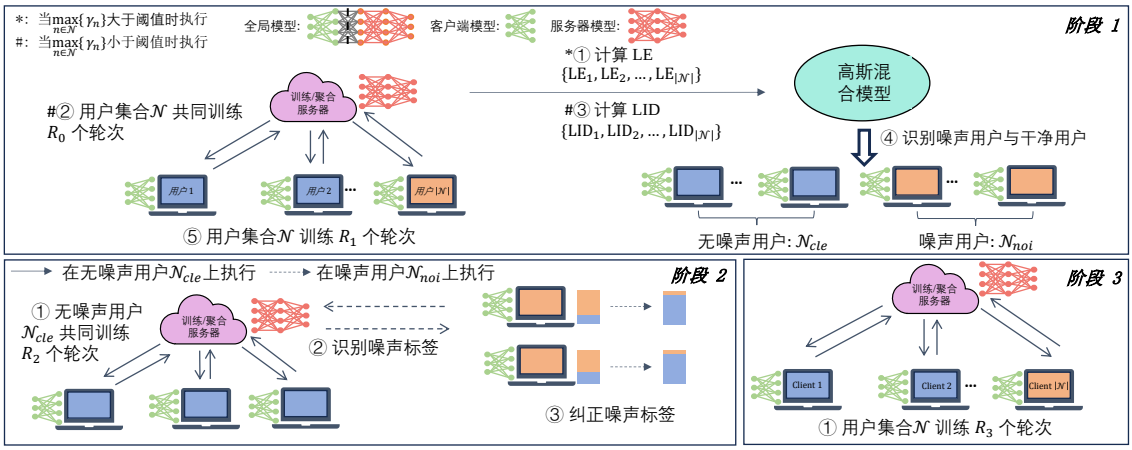


图 3-2　SFL-DCT 概览。

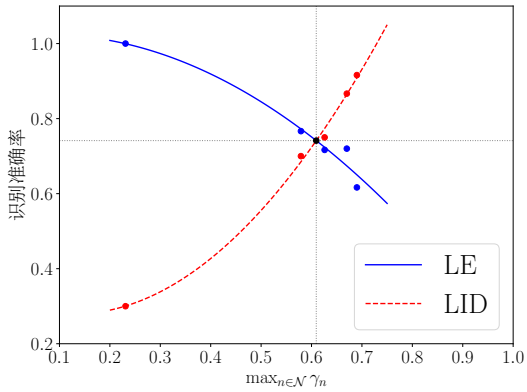


图 3-3　通过 LE 和 LID 方法检测含噪用户的准确率与 $\max_{n\in\mathcal{N}}\gamma_n$ 的关系。

集场景；后者则更适用于 non-IID 数据集。我们建议使用 $\max_{n\in\mathcal{N}}\gamma_n$ 来判断是否存在数据集极度非 IID 的客户端（即仅包含有限种类的标签）。如果 $\max_{n\in\mathcal{N}}\gamma_n > \tau$，则优先采用基于 LE 的方法；否则推荐使用基于 LID 的方法。其中，$\tau$ 是一个可以通过实验经验确定的阈值。

以 CIFAR-10 数据集为例，图 3-3 中的两条曲线展示了在不同 $\max_{n\in\mathcal{N}}\gamma_n$ 值下，LE 和 LID 方法检测含噪客户端的准确率。这两条曲线的交点表示最优的 $\tau$ 值，在该点上两种方法的性能达到平衡。对于这两种方法，训练服务器会通过计算每个客户端的 LID 分数或 LE 分数来评估其是否含有标签噪声。

**LID 分数：**为了计算客户端的 LID 分数，首先让客户端使用 SFL 对全局模型进行 $R_0$ 轮训练。根据训练输出，对每个数据点 $(x_i, \tilde{y}_i)$，其 LID 定义如下[11? ? ]：

$$\mathrm{LID}(x_i, \tilde{y}_i) = -\left(\frac{1}{k}\sum_{j=1}^{k}\log\frac{d_j\left(h\left(x_i, \boldsymbol{\omega}\right)\right)}{d_{max}\left(h\left(x_i, \boldsymbol{\omega}\right)\right)}\right)^{-1}. \tag{3-25}$$

在式 (3-25) 中，$d_j\left(h\left(x_i, \boldsymbol{\omega}\right)\right)$ 表示数据样本 $(x_i, \tilde{y}_i)$ 与其邻近样本 $(x_j, \tilde{y}_j)$ 在特征空间中的欧氏距离。考虑 $(x_i, \tilde{y}_i)$ 的 $k$ 个最近邻样本，即 $k$ 个具有最小 $d_j\left(h\left(x_i, \boldsymbol{\omega}\right)\right)$

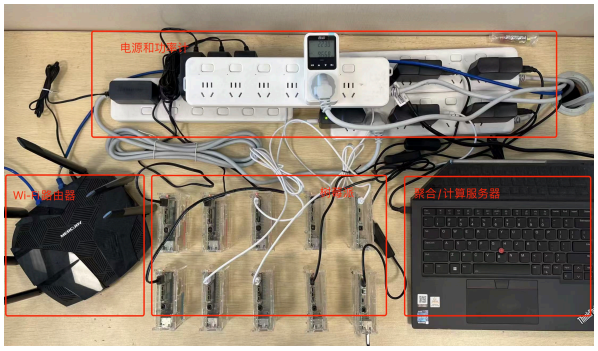


图 3-4　真实测试平台。

的样本。令 $d_{max}\left(h\left(x_i, \boldsymbol{\omega}\right)\right)$ 表示在这 $k$ 个最近邻中与 $(x_j, \tilde{y}_j)$ 的最大距离。

直观上讲，定义在 (3-25) 中的数据样本 LID 反映了该样本与其他样本的接近程度，从而间接揭示了其标签可能为噪声标签的可能性。每个客户端 $n$ 的 LID 分数为其数据集 $\mathcal{D}_n$ 中所有样本 LID 值的平均值：

$$\mathrm{LID}_n = \sum_{(x_i,\tilde{y}_i)\in\mathcal{D}_n} \mathrm{LID}(x_i, \tilde{y}_i)/|\mathcal{D}_n|. \tag{3-26}$$

**LE 分数：**我们提出使用标签的熵来衡量标签噪声。这一想法源于一个直观认识：随机噪声会使标签分布变得不那么集中。具体而言，LE 分数的计算方式如下：

$$\mathrm{LE}_n = -\gamma_n \log(\gamma_n) - (1-\gamma_n)\log(1-\gamma_n). \tag{3-27}$$

随后，SFL-DCT 使用高斯混合模型（GMM）对 LID 或 LE 分数进行分类，从而区分干净客户端与含噪客户端。接着，SFL 训练过程继续进行，直到完成 $R_1$ 轮训练。需要注意的是，LID 的计算需要 $R_0$ 轮训练，而 LE 则不需要。进行至 $R_1$ 轮的训练确保了基于 LID 和基于 LE 的方法在相同训练水平上进行比较。

第二阶段通过使用被归类为干净的客户端（即 $n \in \mathcal{N}_{cle}$）来训练全局模型 $\boldsymbol{\omega}$，以提升模型准确率。训练损失用于识别每个含噪客户端 $n \in \mathcal{N}_{noi}$ 数据集中的噪声标签，因为噪声数据的损失通常较高。训练好的模型 $\boldsymbol{\omega}$ 随后被用于修正刚刚检测出的噪声标签。

在第三阶段，所有客户端 $n \in \mathcal{N}$ 在已修正第二阶段中检测出的噪声标签的数据集 $\mathcal{D}_n'$ 上继续进行训练，共进行 $R_3$ 轮。最终，获得优化后的全局模型。

### 3.4.2　树莓派测试平台的实现

在我们搭建的测试平台上，联邦服务器（fed server）和训练服务器（training server）部署在同一台个人电脑上（处理器为 13th Gen Intel(R) Core(TM) i7-13700K）。10 个 Raspberry Pi 4B 设备作为客户端运行。由于 HTTP 协议具有较强的抗无线错误和丢包能力，我们在数据传输（如模型和梯度传输）中采用了 HTTP 协议。

每个客户端包含三个模块：客户端侧训练模块、HTTP 下载模块和客户端 HTTP 代理模块。服务器端则包括联邦服务器模块、训练服务器模块、HTTP 下载器模块以及 $N$ 个服务器端 HTTP 代理模块。HTTP 下载器与代理模块负责协调客户端与服务器之间的数据传输，同时支持并行数据交换（即双工通信，并允许多个客户端同时发送或接收数据）。

为了通过 HTTP 实现数据传输，每次数据传输都由一个 HTTP 请求触发。这种设计确保了数据交换的高效性与准确性，从而降低了分割-联邦学习的训练延迟，因为 HTTP 协议能够保证可靠的数据传输。

## 3.5　实验部分

### 3.5.1　分割-联邦学习收敛性的实验验证

#### 3.5.1.1　实验设置

我们在 CIFAR-10 和 CIFAR-100 数据集上进行了实验。两个数据集均包含 6 万张图像（5 万张用于训练，1 万张用于测试），不同之处在于 CIFAR-10 包含 10 个类别，而 CIFAR-100 包含 100 个类别。我们使用交叉熵作为损失函数。

为了模拟数据异构性，我们采用了广泛使用的 Dirichlet 分布[33]，并引入一个控制参数 $\alpha$。其中，较小的 $\alpha$ 值表示客户端之间的数据异构性更高。我们选用 ResNet-18 作为模型结构，该网络包含四个残差块，并考虑四种模型切分方式，分别由 $L_c = \{1, 2, 3, 4\}$ 表示，其中 $L_c = n$ 表示模型在第 $n$ 个残差块之后进行切分。

我们将两种主流分布式学习方法作为基准进行比较：联邦学习（FL，特别是 FedAvg[34]）和分割学习（SL）[35]。SFL-V1、SFL-V2、FL 和 SL 的学习率统一设置为 0.01。批量大小 $b_s = 128$，实验运行总轮数为 $T = 200$ 轮。

我们使用以下参数设置：客户端数量 $N = 10$，数据异构性参数 $\beta = 0.1$，本地训练轮数 $E = 5$，其中 $E$ 表示客户端模型聚合前的本地训练次数（即每对每个客户端的数据进行 $E$ 次训练后，其客户端侧模型将在联邦服务器上进行聚合），因此 $\tau = \lceil \frac{D_n}{b_s} \rceil \times E$。为了与标准联邦学习进行公平比较，我们将 $\tau$ 设置为与 $\tilde{\tau}$ 相等。所有实验运行在 CPU（Intel(R) Xeon(R) Gold 5320 @ 2.20GHz）和 GPU（A100-PCIE-80GB）平台上。

#### 3.5.1.2　实验结果

在分割-联邦学习中，各类超参数豆会对于模型的收敛产生影响，本部分实验目标是验证分割-联邦学习在不同超参数下的收敛规律。

每轮训练时数据的迭代次数 $E$ 是可以选择的。一般而言，$E$ 的值过小可能导致用户的模型在没有学习到足够的信息时就被联邦服务器聚合，学到的信息也随之消散；$E$ 的值过大可能导致用户的模型在非独立同分布的数据上产生过大的偏差，联邦服务器无法将大量存在过大偏差的模型聚合为无偏差的模型。本文选择 $E \in \{2, 5, 10\}$ 三个值进行实验。根据图3-5显示，模型的最终准确率相差无几，但 $E = 2$ 时模型的收敛速率更快。

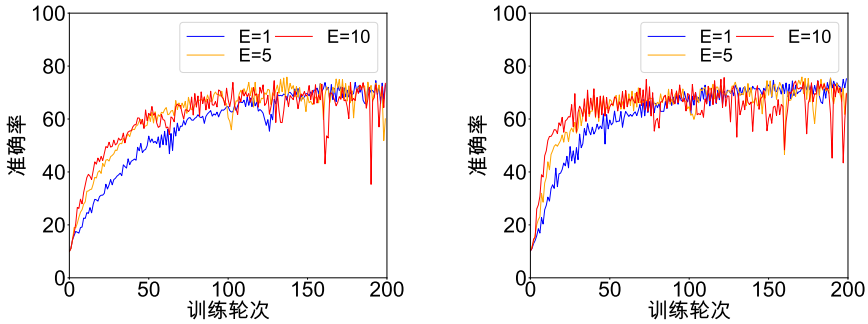


(a) SFL-V1　　(b) SFL-V2

图 3-5　每轮训练数据迭代次数 E 对准确率的影响

参与训练的用户数 $N$ 也会对模型的准确率产生很大的影响。用户数量较少时，每一个用户可以在全局模型中占有较大的比重，可以提升全局模型在所有用户上的泛化能力。但同时全局模型也可能被不均匀的数据严重影响，导致准确率低下。用户数量较多时，每一个用户的模型在全局模型中的比重降低，会降低全局模型的泛化能力。但同时，单个用户的不均匀数据对全局模型的影响也会降低。本文选择 $N \in \{10, 50, 100\}$ 三个值进行实验。根据图3-6显示模型的最终准确率差别不大，$N$ 越大时模型的收敛速率越慢。

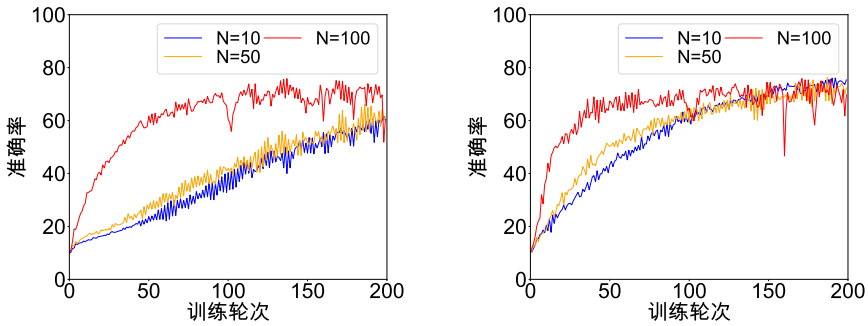


(a) SFL-V1　　(b) SFL-V2

图 3-6　参与训练的用户数 $N$ 对准确率的影响

表 3-1　不同数据集的设置

| 数据集 | CIFAR-10 | CIFAR-100 | Fashion-MNIST |
|---|---|---|---|
| 客户端数量 | 100 | 100 | 50 |
| 模型 | ResNet-18 | ResNet-34 | 10 层 CNN |

每轮参与训练的用户比例 $q$ 会显著影响模型的准确率和收敛速率。当每轮参与训练的比例过低时，模型每轮难以学习到足够的信息，且模型获得的信息总是带有偏向性的，这种情况会严重影响模型的训练。本文选择 $q \in \{0.2, 0.5, 1\}$ 三个值进行实验。根据图3-7显示，随着 q 的增大，模型的收敛速率加快的同时，最终准确率也会提高。

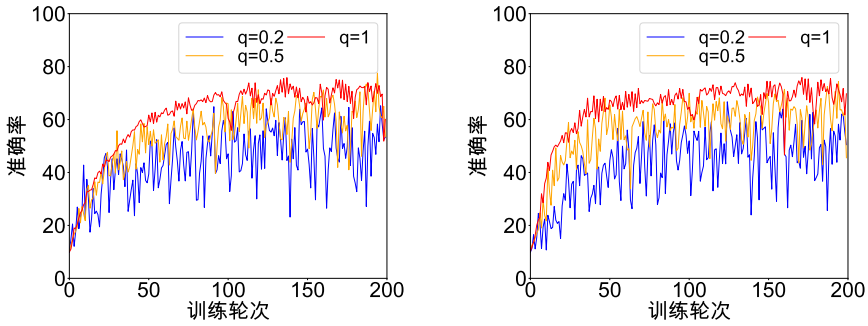


(a) SFL-V1　　(b) SFL-V2

图 3-7　每轮参与训练的用户比例 $q$ 对准确率的影响

### 3.5.2　分割-联邦学习鲁棒性算法的实验验证

#### 3.5.2.1　实验设置

客户端数据同样采用 Dirichlet 分布进行采样，并且也引入控制参数 $\alpha$[33]。其中，$\alpha$ 的值越大，表示数据异构性越低。我们考虑两种场景：独立同分布（IID，$\alpha = \infty$）和非独立同分布（non-IID，$\alpha = 0.1$）。与[11,14,16] 类似，我们通过随机翻转标签的方式模拟标签噪声，即以一定概率（称为噪声率）将样本的标签随机翻转为其他类别。我们在 CIFAR-10 和 CIFAR-100 数据集上设置了 $\{0, 10\%, 20\%, 30\%, 40\%, 50\%, 60\%\}$ 的噪声率，在 Fashion-MNIST 上设置了 $\{40\%, 50\%, 60\%, 70\%, 80\%\}$ 的噪声率。为了便于观察实验结果，我们仅展示了部分噪声设置下的实验结果。

用于训练 SFL 模型的数据集、模型结构以及客户端数量如表 3-1 所示。主要的超参数如下：批量大小设为 128；学习率为 $\eta^r = 0.01$；每轮训练使用 $E = 5$ 个 epoch。我们使用交叉熵作为损失函数。实验所用 GPU 为 A100-80GB，每次训练仅使用一块 GPU。

表 3-2　CIFAR-10 数据集上各算法的最佳平均准确率

| 算法 | 测试准确率 (%) | | | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| | IID | | | | | | Non-IID | | | | | |
| | $\delta = 0.1$ | $\delta = 0.2$ | $\delta = 0.3$ | $\delta = 0.4$ | $\delta = 0.5$ | $\delta = 0.6$ | $\delta = 0.1$ | $\delta = 0.2$ | $\delta = 0.3$ | $\delta = 0.4$ | $\delta = 0.5$ | $\delta = 0.6$ |
| SFL-DCT | 84.66 | **83.84** | **83.15** | **83.15** | **83.07** | **82.07** | **67.20** | **68.31** | **66.15** | **63.12** | **63.33** | **60.99** |
| SFL-V1 | 84.26 | 78.29 | 75.50 | 70.84 | 66.01 | 63.35 | 62.18 | 56.30 | 50.97 | 45.13 | 41.62 | 38.75 |
| SFL-V2 | 84.33 | 78.90 | 74.99 | 70.92 | 67.57 | 64.83 | 65.72 | 59.13 | 53.31 | 47.43 | 43.78 | 40.98 |
| FedCorr | **84.95** | 83.11 | 82.90 | 82.63 | 82.11 | 81.46 | 63.71 | 57.36 | 51.10 | 46.92 | 41.60 | 39.68 |
| FedNoRo | 84.37 | 81.71 | 81.02 | 79.35 | 77.58 | 76.14 | 58.43 | 54.19 | 52.74 | 48.90 | 44.54 | 40.76 |

表 3-3　Fashion-MNIST 数据集上各算法的测试准确率

| 算法 | 测试准确率 (%) | | | | | | | | | |
|---|---|---|---|---|---|---|---|---|---|---|
| | IID | | | | | Non-IID | | | | |
| | $\delta = 0.4$ | $\delta = 0.5$ | $\delta = 0.6$ | $\delta = 0.7$ | $\delta = 0.8$ | $\delta = 0.4$ | $\delta = 0.5$ | $\delta = 0.6$ | $\delta = 0.7$ | $\delta = 0.8$ |
| SFL-DCT | **89.31** | **89.42** | **88.95** | **88.81** | **87.94** | **84.47** | **83.68** | **84.67** | **79.80** | **80.22** |
| SFL-V1 | 85.12 | 84.63 | 84.55 | 83.71 | 83.68 | 74.82 | 71.61 | 66.43 | 64.26 | 64.07 |
| SFL-V2 | 86.07 | 85.78 | 85.14 | 84.05 | 83.84 | 75.78 | 72.68 | 66.86 | 65.51 | 66.15 |
| FedCorr | 87.72 | 87.64 | 87.13 | 87.20 | 86.83 | 80.24 | 79.31 | 76.63 | 76.35 | 75.23 |
| FedNoRo | 86.10 | 85.93 | 84.69 | 84.82 | 83.43 | 81.52 | 80.33 | 80.51 | 78.81 | 78.04 |

### 3.5.3　SFL-DCT 的结果

我们现在评估所提出算法 SFL-DCT 的性能。我们假设在此场景下有 60% 的客户端存在标签噪声[11,14,16]。我们将 SFL-DCT 与两种现有的去噪算法（FedCorr[11] 和 FedNoRo[10]）以及两种基线算法（SFL-V2 和 SFL-V1/FL）①[8] 进行了比较。为了公平比较，我们将这些现有去噪算法转换为基于分割-联邦学习的形式。具体来说，模型被划分为客户端和服务器两部分，训练过程遵循图 3-1 中所示的步骤 1 - 步骤 4。在模型聚合阶段，仅对客户端侧模型进行联邦更新，如图 3-1 中步骤 5 所示。

表 3-2、3-4 和 3-3 分别展示了不同算法在 CIFAR-10、CIFAR-100 和 Fashion-MNIST 数据集上的平均最佳准确率（3 次实验取平均）。我们观察到，不论用户间的数据是否独立同分布，标签噪声对 SFL-DCT 的影响均小于基线算法（即 SFL-V2 和 SFL-V1/FL）。这是因为 SFL-DCT 能够有效检测并纠正标签，从而显著减轻由标签噪声带来的性能下降。与这两种去噪算法（FedCorr 和 FedNoRo）相比，SFL-DCT 在各种设置下均展现出更优的性能。在数据独立同分布场景下，大多数情况下 SFL-DCT 的准确率略高于这两个竞争算法；而在数据非独立同分布场景下，其表现明显优于它们，体现出更强的鲁棒性和更高的准确性。

① 由于 SFL-V1 与 FedAvg 在逻辑上是相同的算法，因此 SFL-V1 的结果也可以代表 FedAvg。

表 3-4　CIFAR-100 数据集（Non-IID 设置）下各算法的最佳平均准确率

| 算法 | 测试准确率 (%) | | | | | |
|---|---|---|---|---|---|---|
| | $\delta = 0.1$ | $\delta = 0.2$ | $\delta = 0.3$ | $\delta = 0.4$ | $\delta = 0.5$ | $\delta = 0.6$ |
| SFL-DCT | **63.56** | **60.03** | **57.76** | **54.11** | **50.86** | **49.23** |
| SFL-V1 | 60.54 | 54.10 | 46.82 | 43.77 | 40.10 | 35.18 |
| SFL-V2 | 61.14 | 54.78 | 47.58 | 43.82 | 39.50 | 35.46 |
| FedCorr | 59.49 | 55.55 | 52.16 | 49.15 | 57.37 | 45.62 |
| FedNoRo | 58.26 | 56.31 | 52.88 | 50.43 | 55.91 | 48.10 |

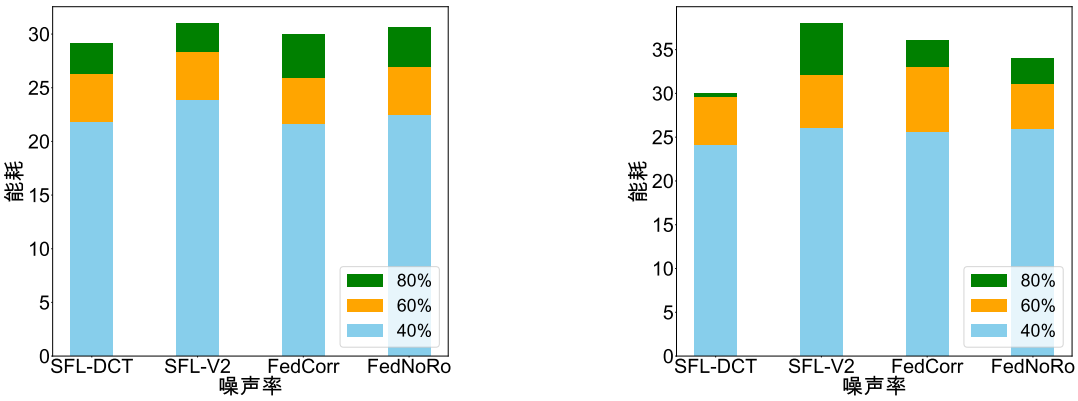


(a) Fashion-MNIST(IID)　　(b) Fashion-MNIST(non-IID)

图 3-8　不同算法的能量消耗对比。

### 3.5.3.1　SFL-DCT 在测试平台上的能耗结果

我们进一步在测试平台中评估了 SFL-DCT 和 SFL-V2 的实际收敛性和能耗（见第 3.4.2 节）。图 3-4 展示了我们的测试平台实验环境。在 SFL-DCT 中，我们将 $R_0$、$R_1$ 和 $R_2$ 设置得远小于 $R_3$，以使得对噪声标签的检测与纠正不会带来显著的计算开销。在每种设置下，我们测量了客户端直到 SFL-V2 收敛时所消耗的能量（单位为 kWh），以便进行公平比较，因为在收敛时 SFL-DCT 的准确率明显高于 SFL-V2。在这个系统中，一个 Raspberry Pi 代表一个客户端，而 PC 作为服务器，它们通过 WIFI 进行通信。我们选用 Fashion-MNIST 数据集，因为它适合计算能力受限的设备。如图 3-8 所示，与 SFL-V2 相比，SFL-DCT 在客户端侧显著降低了能耗。在非独立同分布（non-IID）数据下，能耗降低最多可达 23.30%。

# 第 4 章　分割-联邦学习中轻量化客户端训练方案

## 4.1　无反向传播训练的实现

在无反向传播训练框架中，模型被分解为多个小型计算单元，每个单元都可以通过一种仅前向传播的机制独立更新。在训练过程中，每次迭代时只对其中一个单元或其对应的输出 logits 有选择性地注入噪声。这种设计确保了扰动对整体损失的影响可以明确归因于目标单元，从而无需反向传播即可实现高效的梯度估计。

值得注意的是，准确的梯度估计需要对同一单元在多次迭代中施加不同噪声样本的重复扰动。只有通过对损失响应各种独立扰动的结果进行聚合，才能使估计的梯度收敛到真实的梯度方向。

该训练方法的核心思想在于观察到：对模型组件引入微小扰动可能会导致最终损失的可测量变化。通过分析扰动与损失变化之间的关系，就可以估计出该组件相对于损失的梯度方向。具体来说，给定一个干净输入 $x$，令 $L_{\text{clean}}$ 表示使用模型原始输出计算得到的损失。当一个噪声向量 $\xi$ 被添加到某个选定单元的输出 logits 或内部参数中时，可以得到扰动后的损失 $L_{\text{noisy}}$。该单元参数相对于损失的梯度可近似表示为：

$$\hat{\nabla}_{\theta} L \approx \frac{L_{\text{noisy}} - L_{\text{clean}}}{\varepsilon} \cdot \xi, \tag{4-1}$$

其中 $\theta$ 表示目标单元的参数，$\varepsilon$ 是噪声的缩放因子，而 $\xi$ 是注入的扰动。这个估计的梯度记作 $\hat{\nabla}_{\theta} L$，随后可用于执行参数更新，通常使用随机梯度下降（SGD）或自适应优化器如 Adam。

扰动可以应用于单元的输出激活值，也可以直接作用于其内部参数。这两种方法代表了从局部变化建模全局损失敏感性的两种根本不同的方式。

在第一种情况下，噪声直接施加在单元的输出激活值上。这种方法类似于函数空间中的有限差分逼近，并能够直观估计单元输出的变化如何影响全局损失。第二种策略则将噪声注入单元本身的权重和偏置参数中。此时，批次中的每个样本都对应一个不同的、经过扰动的单元参数版本，有效地在前向传播过程中模拟了一个模型分布。两种方法都能在不依赖反向传播的前提下实现梯度估计，并可无缝集成到标准深度学习流程中。

重要的是，该方法中使用的噪声并非固定不变，而是与模型参数一同进行学习。我们引入一个可学习的参数向量 $\mathbf{p} \in \mathbb{R}^{C}$，其中 $C$ 表示该单元的输出通道数。$\mathbf{p}$

的每一个元素对应一个输出通道，表示所应用噪声尺度的对数值。该参数以某一初始值进行初始化，并在训练过程中根据噪声对损失的影响进行更新。实际的噪声标准差则通过对 $\mathbf{p}$ 进行指数变换获得：

$$\sigma = e^{\mathbf{p}}, \tag{4-2}$$

该表达式确保了噪声尺度的正定性，并支持基于梯度的优化。这种自适应的噪声缩放机制使模型能够根据每个单元的敏感性自动调整扰动幅度，从而实现更稳定且更精确的梯度估计。

此外，该方法支持多种噪声采样分布，包括标准高斯噪声以及低差异序列。这些拟蒙特卡洛方法相比纯随机采样能更均匀地覆盖输入空间，从而提高梯度估计的可靠性。

通过消除对反向传播的依赖，无反向传播训练为在内存受限或架构限制导致传统梯度计算不可行的场景下训练深度神经网络提供了一种有前景的替代方案。

## 4.2　无反向传播训练对分割-联邦学习的性能提升

我们考虑一个包含一个中心服务器和 $n$ 个边缘客户端的分裂学习系统，其中每个客户端 $n \in \{1, 2, \cdots, K\}$ 拥有一个本地数据集 $\mathcal{D}_n = \{(\mathbf{x}_{ni}, y_{ni})\}_{i=1}^{|\mathcal{D}_n|}$，其中 $\mathbf{x}_{ki} \in \mathbb{R}^d$ 是输入特征向量，$y_{ki} \in \mathbb{R}$ 是对应的标签。一个由参数 $\boldsymbol{\omega} \in \mathbb{R}^p$ 表示的神经网络模型被划分为两个部分：客户端子模型 $\boldsymbol{\omega}_c : \mathbb{R}^d \to \mathbb{R}^m$ 和服务端子模型 $\boldsymbol{\omega}_s : \mathbb{R}^m \to \mathbb{R}$，使得对输入 $\mathbf{x}$ 的整体预测表示为：

$$\hat{y} = f_{\boldsymbol{\omega}_s}(f_{\boldsymbol{\omega}_c}(\mathbf{x})) = f_{\boldsymbol{\theta}}(\mathbf{x}), \tag{4-3}$$

其中 $\boldsymbol{\omega} = [\boldsymbol{\omega}_c^\top, \boldsymbol{\omega}_s^\top]^\top$ 表示客户端与服务端参数的拼接。

在基于标准反向传播的训练中，每个客户端通过在一个小批量数据上进行前向和后向传播，计算精确梯度 $\boldsymbol{\nabla}_{\boldsymbol{\omega}_c} L(f_{\boldsymbol{\omega}}(\mathbf{x}), y)$，其中 $L(\cdot, \cdot)$ 表示损失函数。该过程需要在前向传播过程中存储计算图，导致内存消耗为 $M_{bp}$。此过程的计算复杂度记为 $C_{bp}$，每轮迭代中客户端与服务器之间的通信开销为 $T_{bp}$。

相比之下，在将无反向传播的梯度估计方法集成到分裂学习中的情况下，客户端 $n$ 仅执行前向传播来计算中间表示：

$$\mathbf{z}_n = f_{\boldsymbol{\omega}_c}(\mathbf{x}_n), \tag{4-4}$$

然后将其传输至服务器。服务器随后计算最终输出 $\hat{y}_n = f_{\boldsymbol{\omega}_s}(\mathbf{z}_n)$ 并评估损失值 $L_n = L(\hat{y}_n, y_n)$。该损失值返回给客户端，客户端随后使用无反向传播方法估计梯度 $\tilde{\boldsymbol{\nabla}}_{\boldsymbol{\theta}_c} L_n$。由于未在本地执行后向传播，前向计算期间的内存占用减少至大约一

表 4-1　无反向传播训练方法中分割-联邦学习与集中式学习的准确率比较

| 训练框架 | 模型 | 准确率 (%) |
|---|---|---|
| 集中式学习 | ResNet-5 | 64.80 |
| | VGG-8 | 74.30 |
| 分割-联邦学习 | ResNet-5 | 62.22 |
| | VGG-8 | 74.53 |

半，即：

$$M_{ulr} \approx 0.5M_{bp}, \tag{4-5}$$

因为无需存储用于梯度计算的计算图。

此外，通信开销也减半，因为只有中间输出 $\mathbf{z}_n$ 从客户端上传到服务器，而只有一个标量 $L_n$ 从服务器下载到客户端。因此，

$$T_{ulr} \approx 0.5T_{bp}. \tag{4-6}$$

## 4.3　实验结果

本实验在 CIFAR-10 数据集上，基于 ResNet-5 和 VGG-8 两种模型，评估了在分割式联邦学习框架中应用无反向传播训练方法的效果。实验中共有 10 个客户端参与。如表 4-1 所示，采用无反向传播方法进行训练的分割式联邦学习，在测试准确率上接近于集中式训练下使用相同训练策略的结果。

## 4.4　未来研究计划

尽管本研究已初步验证了无反向传播训练方法在分割-联邦学习框架下的可行性，并在 ResNet-5 和 VGG-8 等模型上取得了接近传统基于反向传播训练的准确率表现，但该方向仍处于探索阶段，具有较大的拓展空间。未来的研究将从以下几个方面深入展开：

首先，我们将继续探索无反向传播训练方法在更多类型神经网络模型上的适用性，包括但不限于 Transformer、轻量级 CNN 结构（如 MobileNet、SqueezeNet）以及图神经网络（GNN）。同时，将在更广泛的数据集上进行实验评估，涵盖图像分类、语义分割等任务，以验证该方法在不同任务场景下的泛化能力与稳定性。

其次，为了推动该技术在边缘设备上的实际部署，我们计划使用基于树莓派的测试平台对应用无反向传播训练的分割-联邦学习算法进行全面的性能评估。重点分析其在资源受限环境下的能耗、内存占用、通信负载等关键指标，为后续优

化提供数据支持。通过对比标准分割-联邦学习训练流程，量化无反向传播机制在降低客户端负担方面的实际效益。

此外，针对当前无反向传播方法在高维参数空间中梯度估计精度较低的问题，我们将进一步优化其噪声注入策略与梯度估计方式。例如引入自适应噪声缩放机制、多扰动梯度融合策略，或结合低方差采样技术（如拟蒙特卡洛方法），以提升梯度估计的稳定性和收敛速度。目标是在不牺牲模型准确率的前提下，显著降低客户端的计算与通信开销。

最终，我们希望构建一个高效、稳健且适用于边缘计算场景的分割-联邦学习系统，在保障隐私安全的同时实现高精度、低功耗、低延迟的协同训练模式，为医疗健康、智能物联网等对资源敏感且数据异构性强的应用领域提供技术支持。

# 第 5 章　结论与展望

本课题首次研究了标签噪声和非独立同分布数据同时存在时分割-联邦学习的精度与能耗情况。我们提供了关于标签噪声和非独立同分布数据如何影响分割-联邦学习收敛的第一个理论分析，考虑了均方误差损失和交叉熵损失。分析表明，在均方误差损失下，收敛速率的上界随着噪声方差的增大而增大，在交叉熵损失下，收敛速率的上界随着噪声率的增大而增大。为了解决这个问题，我们提出了一种基于分割-联邦学习的算法，可以有效地在非独立同分布数据下检测和校正噪声标签。在公共数据集和实际测试平台上的实验证明了该方法在准确性和能效方面的优越性能。

在未来的工作中，我们将重点研究分割-联邦学习与无反向传播训练方法的结合，在保证用户隐私的前提下最大程度地优化分割-联邦学习的精度与能耗。

# 参考文献


[1] WANG S, TUOR T, SALONIDIS T, et al. Adaptive federated learning in resource constrained edge computing systems[J]. IEEE journal on selected areas in communications, 2019, 37(6): 1205-1221.

[2] LI X, HUANG K, YANG W, et al. On the convergence of fedavg on non-iid data[C]//Proc. of ICLR. 2020.

[3] KHALED A, MISHCHENKO K, RICHTÁRIK P. Tighter theory for local SGD on identical and heterogeneous data[C]//International Conference on Artificial Intelligence and Statistics. PMLR, 2020: 4519-4529.

[4] KARIMIREDDY S P, KALE S, MOHRI M, et al. Scaffold: Stochastic controlled averaging for federated learning[C]//International conference on machine learning. PMLR, 2020: 5132-5143.

[5] KOLOSKOVA A, LOIZOU N, BOREIRI S, et al. A unified theory of decentralized sgd with changing topology and local updates[C]//International Conference on Machine Learning. PMLR, 2020: 5381-5393.

[6] LI X, HUANG K, YANG W, et al. On the convergence of fedavg on non-iid data[A]. 2019.

[7] LI Y, LYU X. Convergence Analysis of Sequential Federated Learning on Heterogeneous Data [C]//Advances in Neural Information Processing Systems: volume 36. 2023: 56700-56755.

[8] THAPA C, ARACHCHIGE P C M, CAMTEPE S, et al. Splitfed: When federated learning meets split learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 36. 2022: 8485-8493.

[9] KE S, HUANG C, LIU X. On the impact of label noise in federated learning[C]//2023 21st International Symposium on Modeling and Optimization in Mobile, Ad Hoc, and Wireless Networks (WiOpt). IEEE, 2023: 183-190.

[10] WU N, YU L, JIANG X, et al. FedNoRo: Towards noise-robust federated learning by addressing class imbalance and label noise heterogeneity[A]. 2023.

[11] XU J, CHEN Z, QUEK T Q, et al. Fedcorr: Multi-stage federated learning for label noise correction[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10184-10193.

[12] LYCKLAMA H, BURKHALTER L, VIAND A, et al. Rofl: Robustness of secure federated learning[C]//2023 IEEE Symposium on Security and Privacy (SP). IEEE, 2023: 453-476.

[13] YANG S, PARK H, BYUN J, et al. Robust federated learning with noisy labels[J]. IEEE Intelligent Systems, 2022, 37(2): 35-43.

[14] JI X, ZHU Z, XI W, et al. FedFixer: Mitigating Heterogeneous Label Noise in Federated Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 38. 2024: 12830-12838.

[15] ZHOU X, WANG X. Federated label-noise learning with local diversity product regularization [C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 38. 2024: 17141-17149.

[16] LI J, LI G, CHENG H, et al. FedDiv: Collaborative Noise Filtering for Federated Learning with Noisy Labels[C]//Proceedings of the AAAI Conference on Artificial Intelligence: volume 38. 2024: 3118-3126.

[17] LI T, SAHU A K, ZAHEER M, et al. Federated optimization in heterogeneous networks[J]. Proceedings of Machine learning and systems, 2020, 2: 429-450.

[18] REDDI S, CHARLES Z, ZAHEER M, et al. Adaptive federated optimization[A]. 2020.

[19] WU D, ULLAH R, HARVEY P, et al. Fedadapt: Adaptive offloading for iot devices in federated learning[J]. IEEE Internet of Things Journal, 2022, 9(21): 20889-20901.

[20] MA W D K, LEWIS J, KLEIJN W B. The HSIC bottleneck: Deep learning without back-propagation[C]//Proceedings of the AAAI conference on artificial intelligence: volume 34. 2020: 5085-5092.

[21] WANG T, DAI X, LIU Y. Learning with Hilbert–Schmidt independence criterion: A review and new perspectives[J]. Knowledge-based systems, 2021, 234: 107567.

[22] JACOT A, GABRIEL F, HONGLER C. Neural tangent kernel: Convergence and generalization in neural networks[J]. Advances in neural information processing systems, 2018, 31.

[23] NØKLAND A. Direct feedback alignment provides learning in deep neural networks[J]. Advances in neural information processing systems, 2016, 29.

[24] SPALL J C. Multivariate stochastic approximation using a simultaneous perturbation gradient approximation[J]. IEEE transactions on automatic control, 1992, 37(3): 332-341.

[25] SALIMANS T, HO J, CHEN X, et al. Evolution strategies as a scalable alternative to reinforcement learning[A]. 2017.

[26] JIANG J, ZHANG Z, XU C, et al. One forward is enough for neural network training via likelihood ratio method[A]. 2023.

[27] LUKASIK M, BHOJANAPALLI S, MENON A, et al. Does label smoothing mitigate label noise?[C]//Proc. of ICML. PMLR, 2020: 6448-6458.

[28] LI X, HUANG K, YANG W, et al. On the convergence of fedavg on non-iid data[C]//Proc. of ICLR. 2020.

[29] HAN P, HUANG C, TIAN G, et al. Convergence Analysis of Split Federated Learning on Heterogeneous Data[A]. 2024.

[30] FRÉNAY B, VERLEYSEN M. Classification in the presence of label noise: a survey[J]. IEEE transactions on neural networks and learning systems, 2013, 25(5): 845-869.

[31] KARIMIREDDY S P, KALE S, MOHRI M, et al. Scaffold: Stochastic controlled averaging for federated learning[C]//International conference on machine learning. PMLR, 2020: 5132-5143.

[32] HUANG C, TIAN G, TANG M. When minibatch sgd meets splitfed learning: Convergence analysis and performance evaluation[A]. 2023.

[33] HSU T M H, QI H, BROWN M. Measuring the effects of non-identical data distribution for federated visual classification[A]. 2019.

[34] MCMAHAN B, MOORE E, RAMAGE D, et al. Communication-efficient learning of deep networks from decentralized data[C]//Artificial intelligence and statistics. PMLR, 2017: 1273-1282.

[35] VEPAKOMMA P, GUPTA O, SWEDISH T, et al. Split learning for health: Distributed deep learning without sharing raw patient data[J]. ICLR AI for social good workshop, 2019.

# 附录 A

## A.1 均方差损失下含标签噪声的随机梯度的方差

**证明：**为了推导和表述的简洁性，我们将

$$\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}(\boldsymbol{\omega})\|^2]$$

转换为

$$\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}(\boldsymbol{\omega})\|^2],$$

其中 $\epsilon\sim\mathcal{N}(\mu,\sigma^2)$ 表示任意噪声，$\zeta_n^{cle}\sim\mathcal{D}_n^{cle}$。这种转换是等价的，因为任意数据样本中的随机噪声 $\epsilon$ 与干净数据 $(x,y)$ 是相互独立的。同时我们记 $|\zeta_n^{noi}|=|\zeta_n^{cle}|=|\zeta_n|$ 且 $|\mathcal{D}_n^{noi}|=|\mathcal{D}_n^{cle}|=|\mathcal{D}_n|$。

根据公式 (3-18)，我们有

$$\begin{aligned}
&\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)-\boldsymbol{\nabla}F_n^{noi}\left(\boldsymbol{\omega}\right)\right\|^2\right]\\
&\quad=\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\Bigg[\Bigg\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\frac{1}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\zeta_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\\
&\qquad-\left(\boldsymbol{\nabla}F_n^{cle}\left(\boldsymbol{\omega}\right)-\frac{1}{|\mathcal{D}_n|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\right)\Bigg\|^2\Bigg].
\end{aligned}\tag{A-1}$$

令 $L_n^{noi}\triangleq\frac{1}{|\mathcal{D}_n|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)-\frac{1}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\zeta_n^{noi}}2\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)$。则公式 (A-1) 可表示为

$$\begin{aligned}
&\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\boldsymbol{\nabla}F_n^{cle}\left(\boldsymbol{\omega}\right)-L_n^{noi}\|^2\right]\\
&\quad=\mathbb{E}_{\zeta_n^{cle}}\left[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\boldsymbol{\nabla}F_n^{cle}\left(\boldsymbol{\omega}\right)\|^2\right]+\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\|L_n^{noi}\|^2\right]\\
&\qquad+\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[2\langle\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)-\boldsymbol{\nabla}F_n^{cle}\left(\boldsymbol{\omega}\right),L_n^{noi}\rangle\right].
\end{aligned}\tag{A-2}$$

在公式 (A-2) 中，第一项根据假设 3.1 小于 $\phi_n^2$；第三项由于干净数据与噪声相互独立而等于零；第二项可表示为

$$\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\|L_n^{noi}\|^2\right]$$

$$
\begin{aligned}
&= \mathbb{E}_{\epsilon}\left[\left\|\frac{1}{|\mathcal{D}_n|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}} 2\epsilon_i \boldsymbol{\nabla} h\left(x_i;\boldsymbol{\omega}\right)\right\|^2\right] \\
&\quad + \mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\|\frac{1}{|\zeta_n|}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}} 2\epsilon_j \boldsymbol{\nabla} h\left(x_j;\boldsymbol{\omega}\right)\right\|^2\right] \\
&\quad + \mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\frac{1}{|\mathcal{D}_n|}\frac{1}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}\right. \\
&\quad \left. 4\epsilon_i\epsilon_j \boldsymbol{\nabla} h\left(x_i;\boldsymbol{\omega}\right)\boldsymbol{\nabla} h\left(x_j;\boldsymbol{\omega}\right)\right].
\end{aligned} \tag{A-3}
$$

在公式 (A-3) 中，基于小批量随机采样，第一项与最后一项之和等于

$$
\frac{4\sigma^2}{|\mathcal{D}_n^{noi}|^2}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}\left(\boldsymbol{\nabla}_{\omega} h\left(x_i;\boldsymbol{\omega}\right)\right)^2,
$$

中间项等于

$$
\frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|}\sum_{(x_i,y_i+\epsilon_i)\in\mathcal{D}_n^{noi}}\left(\boldsymbol{\nabla}_{\omega} h\left(x_i;\boldsymbol{\omega}\right)\right)^2.
$$

将公式 (A-3) 代入 (A-2)，即完成证明。若对任意 $\left(x_j, y_j+\epsilon_j\right)\in\mathcal{D}_n$ 都有 $\epsilon_j=0$，该分析依然成立。 ■

## A.2 均方差损失下含标签噪声的随机梯度的平方的期望

**证明：**为简化推导，我们将

$$
\mathbb{E}_{\zeta_n^{noi}\sim\mathcal{D}_n^{noi}}[\|\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n^{noi})\|^2]
$$

表示为 $\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}[\|\boldsymbol{g}_n(\boldsymbol{\omega},\zeta_n^{noi})\|^2]$，其中 $\epsilon\sim\mathcal{N}(\mu,\sigma^2)$ 表示任意噪声，$\zeta_n^{cle}\sim\mathcal{D}_n^{cle}$，此为等价变换。

根据公式 (3-18)，我们有

$$
\begin{aligned}
\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{noi}\right)\right\|^2\right] &= \mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\|\boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right)\|^2\right] \\
&\quad - \mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\langle \boldsymbol{g}_n\left(\boldsymbol{\omega},\zeta_n^{cle}\right), \frac{4}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\zeta_n^{noi}}\epsilon_i \boldsymbol{\nabla} h\left(x_i;\boldsymbol{\omega}\right)\right\rangle\right]
\end{aligned}
$$

$$+\mathbb{E}_{\epsilon}\mathbb{E}_{\zeta_n^{cle}}\left[\left\|\frac{2}{|\zeta_n|}\sum_{(x_i,y_i+\epsilon_i)\in\zeta_n^{noi}}\epsilon_i\boldsymbol{\nabla}h\left(x_i;\boldsymbol{\omega}\right)\right\|^2\right]. \quad \text{(A-4)}$$

第一项基于假设 3.2 被 $G_n^2$ 所限制；第二项由于噪声 $\epsilon_i$ 与数据 $(x_i, y_i)$ 相互独立而等于零；由于小批量随机采样，第三项等于

$$\sum_{\zeta_n^{noi}\subset\mathcal{D}_n^{noi}}\frac{4\sigma^2}{|\mathcal{D}_n^{noi}||\zeta_n^{noi}|}\sum_{\left(x_j,y_j+\epsilon_j\right)\in\zeta_n^{noi}}\left(\boldsymbol{\nabla}_{\omega}h\left(x_j;\boldsymbol{\omega}\right)\right)^2.$$

由此完成证明。若对任意 $\left(x_j, y_j+\epsilon_j\right)\in\mathcal{D}_n$ 都有 $\epsilon_j=0$，该分析依然成立。 ■